

İÇİNDEKİLER

ÖZET	iv
ÖNSÖZ	vi
İÇİNDEKİLER	vii
SİMGELER VE KISALTMALAR	ix
1. GİRİŞ	1
1.1. Problem Tanımı	1
1.2 Çalışmanın Amacı ve Kapsamı	2
1.3 Literatürdeki Çalışmalar	3
1.4 Çalışmanın Katkıları	4
1.5 Proje Organizasyonu	5
2. KAYNAK ARAŞTIRMASI	6
2.1 Meme Kanseri ve Histopatoloji Görüntüleri	6
2.2 Derin Öğrenme Tabanlı Tıbbi Görüntü Analizi	6
2.3 Swin Transformer Mimarisi	7
2.4 Vision Transformer (ViT) Mimarisi	8
2.5 ConvNeXt Mimarisi	9
2.6 Özellik Füzyonu Yaklaşımları	10
2.7 Support Vector Machine (SVM)	12
2.8 Grad-CAM ve Yorumlanabilir Yapay Zekâ	13
3. MATERYAL VE YÖNTEM	15
3.1 Kullanılan Veri Seti	15
3.2 Veri Ön İşleme Süreci	16
3.2.1 Patch Extraction Yapısı	17
3.2.2 Arka Plan Temizleme	17
3.2.3 Veri Dengeleme İşlemi	18
3.3 Veri Artırma Teknikleri	18
3.4 Hibrit Derin Öğrenme Mimarisi	19
3.4.1 Vision Transformer Branch	20
3.4.2 ConvNeXt Branch	21
3.5 Özellik Füzyonu Mekanizması	21
3.6 SVM Tabanlı Sınıflandırma	22
3.7 Eğitim Stratejisi ve Hiperparametreler	23
3.8 Performans Değerlendirme Metrikleri	24
3.9 Grad-CAM Görselleştirme Süreci	24
4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA	25
4.1 Eğitim ve Doğrulama Sonuçları	26

4.2 Fusion Model Sonuçları	28
4.3 SVM Sınıflandırma Sonuçları	31
4.4 ROC Eğrisi ve AUC Analizi	32
4.5 Grad-CAM Analizleri	35
4.6 Literatür ile Karşılaştırma	36
4.7 Modelin Güçlü ve Zayıf Yönleri	42
5. SONUÇLAR VE ÖNERİLER	43
5.1 Sonuçlar	43
5.2 Gelecek Çalışmalar İçin Öneriler	44
KAYNAKLAR	46
EKLER	48
EK-A. Geliştirilen Yapay Zekâ Destekli Kullanıcı Arayüzü	48
ÖZGEÇMİŞ	51



T.C.
SELÇUK ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ

**HYBRID DEEP FEATURE FUSION FOR BREAST CANCER
HISTOPATHOLOGY CLASSIFICATION USING
TRANSFORMER-CNN ARCHITECTURES AND SVM**

FATMA BETÜL PEHLİVAN

**MÜHENDİSLİK TASARIMI / BİLGİSAYAR MÜHENDİSLİĞİ
UYGULAMALARI**

06-2026
KONYA
Her Hakkı Saklıdır

PROJE KABUL VE ONAYI

Fatma Betül Pehlivan tarafından hazırlanan “**Hybrid Deep Feature Fusion for Breast Cancer Histopathology Classification Using Transformer-CNN Architectures and SVM**” adlı proje çalışması 01/06/2026 tarihinde aşağıdaki jüri üyeleri tarafından oy birliği/oy çokluğu ile Selçuk Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği bölümünde Mühendislik Tasarımı / Bilgisayar Mühendisliği Uygulamaları Projesi olarak kabul edilmiştir.

Jüri Üyeleri

İmza

Danışman

Dr. Öğr. Üyesi Züleyha Yılmaz Acar

Üye

Doç. Dr. Gül Nihal Güğöl

Üye

Doç. Dr. Adem Gölcük

Yukarıdaki sonucu onaylarım.

Prof. Dr. Nurettin Doğan

Bilgisayar Mühendisliği
Bölüm Başkanı

PROJE BİLDİRİMİ

Bu projedeki bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve proje yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

DECLARATION PAGE

I hereby declare that all information in this document has been obtained and presented in accordance with academic rules and ethical conduct. I also declare that, as required by project rules and conduct, I have fully cited and referenced all material and results that are not original to this work.

İmza

Fatma Betül Pehlivan

Tarih:25/05/2026

ÖZET

MÜHENDİSLİK TASARIMI /BİLGİSAYAR MÜHENDİSLİĞİ UYGULAMALARI PROJESİ

HYBRID DEEP FEATURE FUSION FOR BREAST CANCER HISTOPATHOLOGY CLASSIFICATION USING TRANSFORMER-CNN ARCHITECTURES AND SVM

FATMA BETÜL PEHLİVAN

SELÇUK ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Danışman: Dr. Öğr. Üyesi Züleyha Yılmaz Acar

Haziran 2026, 61 Sayfa

Jüri

Dr. Öğr. Üyesi Züleyha Yılmaz Acar

Doç. Dr. Gül Nihal Güğöl

Doç. Dr. Adem Gölcük

Bu çalışmada, meme kanseri histopatoloji görüntülerinin otomatik sınıflandırılması için hibrit derin öğrenme tabanlı bir karar destek sistemi geliştirilmiştir. Çalışmanın amacı, invaziv duktal karsinom (IDC) pozitif ve negatif doku örneklerini yüksek doğrulukla sınıflandırabilen güçlü bir yapay zekâ modeli oluşturmaktır. Bu kapsamda Vision Transformer (ViT-Base), Swin Transformer (Swin-Tiny) ve ConvNeXt-Tiny mimarilerini bir araya getiren paralel hibrit bir özellik çıkarım yapısı tasarlanmıştır. Elde edilen derin özellikler birleştirilmiş, standartlaştırılmış ve nihai sınıflandırma aşamasında RBF çekirdekli Destek Vektör Makineleri (SVM) kullanılmıştır.

Histopatoloji görüntüleri yama (patch) tabanlı olarak işlenmiş ve veri artırma teknikleri ile modelin genelleme yeteneği geliştirilmiştir. Ayrıca veri seti dengelenerek sınıf dengesizliği problemi azaltılmıştır. Model performansı doğruluk, kesinlik, duyarlılık, F1-Skoru ve ROC-AUC metrikleri kullanılarak değerlendirilmiştir. Deneysel sonuçlar, önerilen hibrit yapının test kümesinde %91.46 doğruluk, %91.42 F1-Skoru ve 0.9682 ROC-AUC değeri elde ettiğini göstermiştir. Ayrıca Grad-CAM tabanlı görselleştirme yöntemleri kullanılarak modelin dikkat bölgeleri analiz edilmiş ve yorumlanabilirlik artırılmıştır.

Elde edilen sonuçlar, önerilen Transformer-CNN ve SVM tabanlı hibrit yaklaşımın meme kanseri histopatoloji görüntülerinin sınıflandırılmasında etkili ve yüksek performanslı bir yöntem olduğunu göstermektedir.

Anahtar Kelimeler: Breast Cancer Classification, Computational Pathology, ConvNeXt, Deep Learning, Feature Fusion, Histopathology Images, Support Vector Machine (SVM), Swin Transformer, Vision Transformer(ViT)

ABSTRACT

ENGINEERING DESIGN / COMPUTER ENGINEERING APPLICATIONS PROJECT

HYBRID DEEP FEATURE FUSION FOR BREAST CANCER HISTOPATHOLOGY CLASSIFICATION USING TRANSFORMER-CNN ARCHITECTURES AND SVM

FATMA BETÜL PEHLİVAN

**SELCUK UNIVERSITY
FACULTY OF TECHNOLOGY
DEPARTMENT OF COMPUTER ENGINEERING**

Advisor: Dr. Öğr. Üyesi Züleyha Yılmaz Acar

June 2026, 61 Pages

Jury

Dr. Öğr. Üyesi Züleyha Yılmaz Acar

Doç. Dr. Gül Nihal Güğöl

Doç. Dr. Adem Gölcük

This study presents a hybrid deep learning-based decision support system for the automatic classification of breast cancer histopathology images. The main objective of the study is to develop a robust artificial intelligence model capable of accurately classifying invasive ductal carcinoma (IDC) positive and negative tissue samples. In this context, a parallel hybrid feature extraction architecture combining Vision Transformer (ViT-Base), Swin Transformer (Swin-Tiny), and ConvNeXt-Tiny models was designed. The extracted deep features were fused, standardized, and classified using a Support Vector Machine (SVM) with an RBF kernel.

Histopathology images were processed using a patch-based approach, and data augmentation techniques were applied to improve the generalization capability of the model. In addition, a balanced dataset distribution was established to reduce the class imbalance problem. Model performance was evaluated using Accuracy, Precision, Recall, F1-Score, and ROC-AUC metrics. Experimental results demonstrated that the proposed hybrid architecture achieved 91.46% Accuracy, 91.42% F1-Score, and 0.9682 ROC-AUC on the independent test set. Furthermore, Grad-CAM-based visualization techniques were utilized to analyze the attention regions of the model and improve interpretability.

The obtained results indicate that the proposed Transformer-CNN and SVM-based hybrid approach is an effective and high-performance method for the classification of breast cancer histopathology images.

Keywords: Breast Cancer Classification, Computational Pathology, ConvNeXt, Deep Learning, Histopathology Images, Support Vector Machine (SVM), Swin Transformer, Vision Transformer (ViT)

ÖNSÖZ

Bu proje kapsamında, meme kanseri histopatoloji görüntülerinin otomatik sınıflandırılmasına yönelik hibrit derin öğrenme tabanlı bir karar destek sistemi geliştirilmiştir. Çalışma sürecinde yapay zekâ, bilgisayarlı görü ve tıbbi görüntü analizi alanlarında kullanılan güncel yöntemler detaylı olarak incelenmiş; Transformer ve CNN tabanlı mimarilerin güçlü yönlerini bir araya getiren paralel hibrit bir model mimarisi tasarlanmıştır.

Özellikle Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özelliklerin birleştirilmesi ve Support Vector Machine (SVM) tabanlı sınıflandırma yaklaşımı ile yüksek doğruluk ve genelleme performansı sağlayan bir yapı oluşturulmuştur.

Proje geliştirme sürecinde veri ön işleme, yama (patch) tabanlı görüntü işleme, veri artırma teknikleri, özellik füzyonu, model eğitimi ve performans değerlendirme aşamaları ayrıntılı olarak gerçekleştirilmiştir. Ayrıca Grad-CAM tabanlı görselleştirme yöntemleri kullanılarak modelin karar mekanizmasının yorumlanabilirliği artırılmış ve elde edilen sonuçların klinik açıdan daha anlamlı hale gelmesi hedeflenmiştir.

Bu çalışmanın gerçekleştirilmesi sürecinde bilgi, deneyim ve yönlendirmeleriyle destek sağlayan değerli danışman hocama teşekkürlerimi sunarım. Ayrıca eğitim hayatım boyunca maddi ve manevi desteklerini her zaman hissettiğim aileme en içten teşekkürlerimi ifade ederim.

Hazırlanan bu çalışmanın, yapay zekâ destekli tıbbi karar sistemleri ve bilgisayar destekli histopatoloji görüntü analizi alanlarında yapılacak gelecekteki akademik çalışmalara katkı sağlaması temenni edilmektedir.

Fatma Betül Pehlivan

Konya / 2026

SİMGELER VE KISALTMALAR

Simgeler

α	Öğrenme oranı (Learning Rate)
λ	Düzenleştirme katsayısı
$f(x)$	Aktivasyon fonksiyonu
N	Toplam örnek sayısı
d	Özellik vektörü boyutu
x_i	Giriş özellik vektörü
y_i	Sınıf etiketi
σ	Standart sapma
μ	Ortalama değer
Σ	Toplama işlemi

Kısaltmalar

AI	Artificial Intelligence
AUC	Area Under Curve
CNN	Convolutional Neural Network
ConvNeXt	Convolutional Next Network
F1-Score	Harmonik Ortalama Başarım Ölçütü
GPU	Graphics Processing Unit
Grad-CAM	Gradient-weighted CAM
IDC	Invasive Ductal Carcinoma
ROC	Receiver Operating Characteristic
ReLU	Rectified Linear Unit
SVM	Support Vector Machine
ViT	Vision Transformer

1. GİRİŞ

Meme kanseri, dünya genelinde kadınlarda en sık görülen kanser türlerinden biri olup erken teşhis edilmediği durumlarda ölüm oranı yüksek hastalıklar arasında yer almaktadır. Kanserli dokuların erken aşamada doğru şekilde tespit edilmesi, hastalığın tedavi sürecinin planlanması ve hasta yaşam süresinin artırılması açısından kritik öneme sahiptir. Histopatolojik görüntüleme yöntemleri, meme kanserinin tanılanmasında en güvenilir yöntemlerden biri olarak kabul edilmektedir. Ancak histopatoloji görüntülerinin manuel olarak incelenmesi uzman patologlar açısından zaman alıcı olmakta ve yorum farklılıkları nedeniyle tanısız hatalara yol açabilmektedir.

Son yıllarda yapay zekâ ve derin öğrenme tabanlı yöntemlerin gelişmesiyle birlikte tıbbi görüntü analizi alanında önemli ilerlemeler kaydedilmiştir. Özellikle Convolutional Neural Network (CNN) tabanlı modeller, histopatolojik görüntülerden otomatik özellik çıkarımı yapabilmeleri sayesinde yüksek başarı oranları elde etmiştir. Bununla birlikte Vision Transformer (ViT) ve Swin Transformer gibi Transformer tabanlı yeni nesil mimariler, görüntü içerisindeki uzun menzilli ilişkileri daha etkili öğrenebilme yetenekleri sayesinde tıbbi görüntü sınıflandırma problemlerinde dikkat çekici sonuçlar ortaya koymuştur. [1]

Histopatoloji görüntüleri yüksek çözünürlüklü ve karmaşık doku yapıları içermektedir. Bu nedenle tek bir model kullanılarak hem lokal hücresel detayların hem de global yapısal örüntülerin etkili biçimde öğrenilmesi her zaman mümkün olmamaktadır. CNN tabanlı modeller lokal özellik çıkarımında başarılı olurken, Transformer tabanlı modeller görüntünün genel bağlamsal ilişkilerini daha iyi analiz edebilmektedir. Bu durum, farklı mimarilerin güçlü yönlerini bir araya getiren hibrit derin öğrenme sistemlerinin önemini artırmaktadır. [2]

Bu çalışmada meme kanseri histopatoloji görüntülerinin sınıflandırılması amacıyla Vision Transformer (ViT-Base), Swin Transformer (Swin-Tiny) ve ConvNeXt-Tiny mimarilerini bir araya getiren hibrit bir derin öğrenme tabanlı karar destek sistemi geliştirilmiştir. Model yapısında farklı ağlardan elde edilen derin özellikler birleştirilmiş, normalize edilmiş ve Support Vector Machine (SVM) tabanlı sınıflandırıcı ile son tahmin işlemi gerçekleştirilmiştir. Ayrıca Grad-CAM tabanlı görselleştirme teknikleri kullanılarak modelin karar mekanizmasının yorumlanabilirliği artırılmıştır. [1]

Geliştirilen hibrit mimarinin performansı Accuracy, Precision, Recall, F1-Score ve ROC-AUC gibi performans ölçütleri kullanılarak değerlendirilmiştir. Elde edilen sonuçlar, önerilen hibrit yapının meme kanseri histopatoloji görüntülerinin sınıflandırılmasında yüksek doğruluk ve güçlü genelleme kabiliyeti sunduğunu göstermektedir.

1.1. Problem Tanımı

Meme kanseri tanısında kullanılan histopatoloji görüntülerinin manuel olarak değerlendirilmesi uzmanlık gerektiren karmaşık bir süreçtir. Histopatolojik inceleme sırasında patologların yüksek çözünürlüklü görüntüler üzerinde binlerce hücresel yapıyı analiz etmesi gerekmektedir. Bu durum değerlendirme süresini artırmakta ve insan kaynaklı hata olasılığını yükseltmektedir.

Özellikle yoğun veri içeren histopatoloji görüntülerinde küçük yapısal farklılıkların gözden kaçabilmesi yanlış sınıflandırmalara neden olabilmektedir.

Geleneksel bilgisayar destekli görüntü işleme yöntemlerinde manuel özellik çıkarımı yapılması gerekmektedir. Ancak histopatolojik görüntüler karmaşık doku örüntülerine sahip olduğu için manuel özellik çıkarımı çoğu zaman yetersiz kalmaktadır. Derin öğrenme yöntemleri otomatik özellik öğrenme yetenekleri sayesinde bu problemi

önemli ölçüde azaltmıştır. Buna rağmen tek bir derin öğrenme mimarisi kullanıldığında modelin hem lokal hem de global özellikleri aynı anda etkili biçimde öğrenmesi zorlaşabilmektedir.

Transformer tabanlı mimariler global ilişkileri öğrenmede başarılı olurken CNN tabanlı modeller lokal doku detaylarını daha etkili analiz etmektedir. Bu nedenle farklı mimarilerin güçlü yönlerini bir araya getiren hibrit sistemlerin geliştirilmesi önemli bir araştırma problemi hâline gelmiştir. Ayrıca tıbbi karar destek sistemlerinde yalnızca yüksek doğruluk yeterli olmamakta, modelin karar süreçlerinin yorumlanabilir olması da gerekmektedir. [1] ,[2]

Bu çalışma kapsamında meme kanseri histopatoloji görüntülerinin daha doğru, güvenilir ve yorumlanabilir şekilde sınıflandırılması problemi ele alınmıştır. Bu doğrultuda Transformer ve CNN tabanlı mimarileri bir araya getiren hibrit bir derin öğrenme sistemi geliştirilmiş ve model performansı detaylı olarak analiz edilmiştir.

1.2 Çalışmanın Amacı ve Kapsamı

Bu çalışmanın temel amacı, meme kanseri histopatoloji görüntülerinin otomatik olarak sınıflandırılabilmesi için yüksek performanslı hibrit bir derin öğrenme tabanlı karar destek sistemi geliştirmektir. Çalışmada, farklı derin öğrenme mimarilerinin güçlü yönlerinden yararlanılarak daha güvenilir ve başarılı bir sınıflandırma sistemi oluşturulması hedeflenmiştir.

Bu doğrultuda Vision Transformer (ViT-Base), Swin Transformer (Swin-Tiny) ve ConvNeXt-Tiny mimarileri birlikte kullanılarak paralel hibrit bir yapı tasarlanmıştır. Transformer tabanlı modellerin global bağlamsal ilişkileri öğrenme yetenekleri ile CNN tabanlı modellerin lokal özellik çıkarımındaki başarısının bir araya getirilmesi amaçlanmıştır. Böylece histopatolojik görüntüler içerisindeki hem hücresel detayların hem de genel doku örüntülerinin daha etkili şekilde öğrenilmesi hedeflenmiştir. [3]

Çalışma kapsamında meme kanseri histopatoloji veri seti üzerinde çeşitli veri ön işleme adımları uygulanmıştır. İlk olarak yüksek çözünürlüklü histopatoloji görüntüleri belirli boyutlarda parçalara ayrılmış, ardından arka plan temizleme işlemleri gerçekleştirilmiştir. Veri çeşitliliğini artırmak ve aşırı öğrenmeyi azaltmak amacıyla veri artırma tekniklerinden yararlanılmıştır. Bu süreçte döndürme, yatay-dikey çevirme, affine dönüşüm, Gaussian blur ve renk değişimi gibi veri artırma yöntemleri uygulanmıştır.

Model mimarisinde ViT, Swin Transformer ve ConvNeXt ağlarından elde edilen derin özellikler birleştirilerek ortak bir hibrit özellik vektörü oluşturulmuştur. Özellik füzyonu sonrasında normalize edilen bu özellikler, Support Vector Machine (SVM) tabanlı sınıflandırıcıya aktarılmıştır. Nihai sınıflandırma işlemi SVM modeli ile gerçekleştirilmiştir.

Çalışmanın bir diğer amacı ise geliştirilen sistemin yorumlanabilirliğini artırmaktır. Bu doğrultuda Grad-CAM tabanlı görselleştirme yöntemleri kullanılarak modelin hangi bölgeler üzerinden karar verdiği analiz edilmiştir. Böylece sistemin yalnızca yüksek doğruluk sağlaması değil, aynı zamanda klinik açıdan yorumlanabilir sonuçlar üretmesi amaçlanmıştır.

Geliştirilen hibrit modelin performansı Accuracy, Precision, Recall, F1-Score, Balanced Accuracy ve ROC-AUC gibi performans değerlendirme metrikleri kullanılarak analiz edilmiştir. Elde edilen sonuçlar mevcut literatürdeki çalışmalar ile karşılaştırılarak önerilen yaklaşımın etkinliği değerlendirilmiştir. [3]

1.3 Literatürdeki Çalışmalar

Son yıllarda yapay zekâ ve derin öğrenme tabanlı yöntemlerin tıbbi görüntü analizi alanında yaygın şekilde kullanılmaya başlanmasıyla birlikte, meme kanseri histopatoloji görüntülerinin otomatik sınıflandırılmasına yönelik çalışmalar önemli ölçüde artmıştır. Özellikle derin öğrenme modelleri, yüksek boyutlu histopatoloji görüntülerinden otomatik özellik çıkarabilme yetenekleri sayesinde geleneksel görüntü işleme yöntemlerine kıyasla daha başarılı sonuçlar sunmaktadır.

Histopatoloji görüntülerinin analizine yönelik ilk çalışmalarda geleneksel makine öğrenmesi yöntemleri kullanılmıştır. Bu çalışmalarda görüntülerden manuel olarak çıkarılan renk, doku ve şekil tabanlı özellikler sınıflandırma algoritmalarına aktarılmıştır. Ancak manuel özellik çıkarım süreçlerinin uzman bağımlılığı içermesi ve karmaşık histopatolojik örüntüleri yeterince temsil edememesi nedeniyle derin öğrenme tabanlı yaklaşımlar ön plana çıkmıştır. [3] ,[4]

Convolutional Neural Network (CNN) tabanlı mimariler, histopatoloji görüntü sınıflandırmasında yaygın olarak kullanılan yöntemlerden biri olmuştur. Özellikle ResNet, DenseNet ve EfficientNet gibi modellerin meme kanseri sınıflandırma problemlerinde başarılı performans gösterdiği rapor edilmiştir. CNN tabanlı modeller, lokal hücresel yapıları ve doku örüntülerini öğrenme konusunda önemli avantajlar sağlamaktadır. Bununla birlikte yalnızca lokal özelliklere odaklanmaları nedeniyle görüntü içerisindeki uzun menzilli ilişkileri öğrenmede sınırlı kalabilmektedirler. [8]

Son yıllarda Transformer tabanlı mimariler bilgisayarlı görü alanında dikkat çekici başarılar elde etmiştir. Vision Transformer (ViT) modeli, görüntüleri belirli boyutlardaki patch yapılarına ayırarak self-attention mekanizması üzerinden işlemekte ve görüntü içerisindeki global bağlamsal ilişkileri öğrenebilmektedir. ViT tabanlı modellerin özellikle büyük veri kümelerinde güçlü performans sunduğu bildirilmektedir. Ancak yüksek hesaplama maliyeti ve geniş veri gereksinimi önemli dezavantajları arasında yer almaktadır. [3] ,[4]

ViT mimarisinin geliştirilmiş versiyonlarından biri olan Swin Transformer modeli ise shifted window attention mekanizması sayesinde hem lokal hem de global özellikleri daha verimli biçimde öğrenebilmektedir. Swin Transformer mimarisi, hiyerarşik yapısı sayesinde yüksek çözünürlüklü histopatoloji görüntülerinin analizinde başarılı sonuçlar vermekte ve daha düşük hesaplama maliyetleri sunabilmektedir. [8]

CNN tabanlı modern mimarilerden biri olan ConvNeXt modeli ise klasik convolutional ağ yapılarının modern Transformer tasarım prensipleriyle yeniden düzenlenmesiyle geliştirilmiştir. ConvNeXt mimarisi, lokal özellik çıkarımı ve stabil eğitim performansı açısından başarılı sonuçlar ortaya koymaktadır. Özellikle medikal görüntü analizinde hücresel detayların öğrenilmesinde etkili olduğu bildirilmektedir.

Literatürde yapılan çalışmalar incelendiğinde, farklı derin öğrenme mimarilerinin birlikte kullanıldığı hibrit yaklaşımların daha başarılı sonuçlar üretebildiği görülmektedir. Özellikle CNN ve Transformer tabanlı feature fusion yaklaşımlarının hem lokal hücresel detayların hem de global doku örüntülerinin birlikte öğrenilmesine katkı sağladığı belirtilmektedir. Hibrit modeller sayesinde farklı mimarilerden elde edilen derin özellikler tek bir özellik uzayında birleştirilerek daha güçlü temsil öğrenimi gerçekleştirilebilmektedir.

Bunun yanında son yıllarda model yorumlanabilirliği konusu da önemli bir araştırma alanı hâline gelmiştir. Özellikle Grad-CAM gibi görselleştirme yöntemleri kullanılarak modellerin hangi görüntü bölgelerine odaklandığı analiz edilebilmektedir. Bu yöntemler, derin öğrenme tabanlı sistemlerin klinik açıdan güvenilirliğini artırmak açısından önemli katkılar sunmaktadır.

Bu çalışmada ise literatürdeki mevcut yaklaşımlardan farklı olarak Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarileri paralel hibrit bir yapı içerisinde birleştirilmiş, elde edilen derin özellikler feature fusion yöntemi ile bütünleştirilmiş ve nihai sınıflandırma işlemi Support Vector Machine (SVM) kullanılarak gerçekleştirilmiştir. Ayrıca Grad-CAM tabanlı analizler ile modelin yorumlanabilirliğinin artırılması amaçlanmıştır.

Çalışma	Kullanılan Model	Temel Özellik	Sınırlılık
CNN tabanlı yaklaşımlar	ResNet / EfficientNet	Lokal özellik öğrenimi güçlü	Global ilişkiler sınırlı
Transformer tabanlı yaklaşımlar	ViT / Swin Transformer	Global bağlamsal öğrenme başarılı	Yüksek hesaplama maliyeti
Hibrit modeller	CNN + Transformer	Lokal ve global özelliklerin birlikte öğrenilmesi	Karmaşık mimari yapısı
Önerilen çalışma	ViT + Swin + ConvNeXt + SVM	Hibrit feature fusion ve yüksek sınıflandırma performansı	Yüksek GPU gereksinimi

Çizelge 1.1. Literatürde kullanılan derin öğrenme tabanlı meme kanseri histopatoloji sınıflandırma yaklaşımlarının genel karşılaştırması

1.4 Çalışmanın Katkıları

Bu çalışmada meme kanseri histopatoloji görüntülerinin sınıflandırılmasına yönelik hibrit derin öğrenme tabanlı özgün bir karar destek sistemi geliştirilmiştir. Çalışma kapsamında farklı derin öğrenme mimarilerinin güçlü yönleri bir araya getirilerek yüksek performanslı ve yorumlanabilir bir yapı oluşturulmuştur.

Çalışmanın literatüre ve uygulama alanına sağladığı temel katkılar aşağıda sunulmuştur:

- Vision Transformer (ViT-Base), Swin Transformer (Swin-Tiny) ve ConvNeXt-Tiny mimarilerini paralel olarak kullanan hibrit bir derin öğrenme tabanlı özellik çıkarım sistemi geliştirilmiştir.
- Transformer tabanlı modellerin global bağlamsal öğrenme yeteneği ile CNN tabanlı modellerin lokal özellik çıkarım başarısı feature fusion yaklaşımı ile aynı sistem içerisinde birleştirilmiştir.
- Hibrit mimariden elde edilen yüksek boyutlu derin özellikler standardizasyon işleminden geçirilmiş ve nihai sınıflandırma aşamasında RBF çekirdekli Support Vector Machine (SVM) algoritması kullanılmıştır.
- Veri ön işleme sürecinde patch extraction, arka plan temizleme, veri dengeleme ve veri artırma teknikleri uygulanarak modelin genelleme performansının artırılması amaçlanmıştır.

- Geliştirilen hibrit model Accuracy, Precision, Recall, F1-Score, Balanced Accuracy ve ROC-AUC metrikleri kullanılarak değerlendirilmiş; Grad-CAM tabanlı analizler ile modelin karar verme süreçlerinin yorumlanabilirliği artırılmıştır.

1.5 Proje Organizasyonu

Bu proje çalışması beş ana bölümden oluşmaktadır.

Birinci bölümde çalışmanın problem tanımı, amacı, kapsamı, literatürdeki benzer çalışmalar ve çalışmanın temel katkıları sunulmuştur.

İkinci bölümde meme kanseri histopatoloji görüntüleri, derin öğrenme tabanlı tıbbi görüntü analizi yöntemleri, Vision Transformer, Swin Transformer, ConvNeXt mimarileri, özellik füzyonu yöntemleri, Support Vector Machine (SVM) algoritması ve Grad-CAM tabanlı yorumlanabilir yapay zekâ yaklaşımları hakkında kuramsal bilgiler verilmiştir.

Üçüncü bölümde çalışmada kullanılan veri seti, veri ön işleme aşamaları, patch extraction işlemleri, veri artırma teknikleri, önerilen hibrit derin öğrenme mimarisi, özellik füzyonu mekanizması, SVM tabanlı sınıflandırma süreci ve performans değerlendirme yöntemleri ayrıntılı olarak açıklanmıştır.

Dördüncü bölümde geliştirilen hibrit modelin deneysel sonuçları sunulmuş; eğitim-doğrulama performansları, confusion matrix analizleri, ROC eğrileri, Grad-CAM görselleştirmeleri ve literatür karşılaştırmaları değerlendirilmiştir.

Beşinci ve son bölümde çalışmanın genel sonuçları özetlenmiş, elde edilen bulgular değerlendirilmiş ve gelecekte gerçekleştirilebilecek çalışmalar için öneriler sunulmuştur.

2. KAYNAK ARAŞTIRMASI

Bu bölümde meme kanseri histopatoloji görüntülerinin analizi, derin öğrenme tabanlı tıbbi görüntü işleme yöntemleri ve çalışmada kullanılan temel yapay zekâ mimarileri hakkında kuramsal bilgiler sunulmuştur. İlk olarak meme kanseri ve histopatoloji görüntülerinin yapısı açıklanmış, ardından derin öğrenme tabanlı görüntü analizi yaklaşımları incelenmiştir. Devamında Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarilerinin çalışma prensipleri ele alınmış; özellik füzyonu yöntemleri, Support Vector Machine (SVM) algoritması ve Grad-CAM tabanlı yorumlanabilir yapay zekâ teknikleri detaylandırılmıştır. Ayrıca literatürde bu yöntemlerin medikal görüntü analizi alanındaki kullanımına ilişkin çalışmalar değerlendirilmiştir.

2.1 Meme Kanseri ve Histopatoloji Görüntüleri

Meme kanseri, dünya genelinde kadınlarda en yaygın görülen kanser türlerinden biri olup erken teşhis edilmediği durumlarda ölüm riski yüksek hastalıklar arasında yer almaktadır. Kanserli hücrelerin erken evrede doğru şekilde tespit edilmesi, tedavi sürecinin planlanması ve hasta yaşam süresinin artırılması açısından büyük önem taşımaktadır. Bu nedenle bilgisayar destekli tanı sistemleri ve yapay zekâ tabanlı medikal görüntü analiz yöntemleri son yıllarda yoğun şekilde araştırılmaktadır.

Histopatoloji, biyopsi veya cerrahi operasyonlar sonucunda elde edilen doku örneklerinin mikroskopik düzeyde incelenmesi işlemidir. Histopatolojik inceleme sürecinde doku örnekleri özel boyama yöntemleri kullanılarak hazırlanmakta ve yüksek çözünürlüklü mikroskop görüntüleri elde edilmektedir. Özellikle Hematoksilen ve Eozin (H&E) boyama yöntemi, hücresel yapıların belirginleştirilmesinde yaygın olarak kullanılmaktadır. [11]

Histopatoloji görüntüleri oldukça yüksek çözünürlüğe sahip olup karmaşık doku örüntüleri içermektedir. Kanserli ve sağlıklı dokular arasındaki farklar çoğu zaman hücresel düzeyde küçük yapısal değişiklikler şeklinde ortaya çıkmaktadır. Bu nedenle görüntülerin manuel olarak incelenmesi uzman patologlar açısından zaman alıcı ve zor bir süreç oluşturmaktadır. Ayrıca farklı uzmanların aynı görüntü üzerinde farklı yorumlar yapabilmesi tanısal tutarsızlıklara neden olabilmektedir. [12]

Geleneksel bilgisayar destekli tanı sistemlerinde görüntülerden renk, doku ve şekil tabanlı özellikler manuel olarak çıkarılmaktadır. Ancak histopatoloji görüntülerinin yüksek karmaşıklığı nedeniyle manuel özellik çıkarımı çoğu zaman yetersiz kalmaktadır. Derin öğrenme tabanlı yöntemler ise görüntülerden otomatik özellik öğrenebilme yetenekleri sayesinde bu problemin çözümünde önemli avantajlar sağlamaktadır.

Histopatoloji görüntülerinin analizinde kullanılan derin öğrenme modelleri genellikle yüksek boyutlu görüntüleri daha küçük parçalara ayırarak işlemektedir. Bu yöntem sayesinde hücresel detaylar daha etkili şekilde öğrenilebilmekte ve modelin hesaplama maliyeti azaltılabilmektedir. Özellikle patch extraction yaklaşımı, büyük boyutlu histopatoloji görüntülerinin analizinde yaygın olarak kullanılmaktadır.

Bu çalışmada kullanılan veri setinde meme kanseri histopatoloji görüntüleri belirli boyutlardaki parçalara ayrılmış ve ön işleme aşamalarından geçirilmiştir. Ardından elde edilen görüntüler hibrit derin öğrenme mimarisine aktarılmıştır. Böylece hem lokal hücresel detayların hem de global doku örüntülerinin etkili biçimde öğrenilmesi amaçlanmıştır.

2.2 Derin Öğrenme Tabanlı Tıbbi Görüntü Analizi

Derin öğrenme, çok katmanlı yapay sinir ağları kullanarak verilerden otomatik özellik öğrenebilen bir makine öğrenmesi yaklaşımıdır. Özellikle son yıllarda görüntü işleme alanında elde edilen başarılı sonuçlar sayesinde tıbbi görüntü analizi çalışmalarında yaygın olarak kullanılmaya başlanmıştır. Geleneksel görüntü işleme yöntemlerinde manuel özellik çıkarımı yapılırken, derin öğrenme modelleri görüntülerden ayırt edici özellikleri doğrudan öğrenebilmektedir. [15]

Tıbbi görüntü analizi alanında manyetik rezonans görüntüleme (MRI), bilgisayarlı tomografi (CT), ultrason ve histopatoloji görüntüleri gibi farklı veri türleri üzerinde derin öğrenme tabanlı yöntemler kullanılmaktadır. Özellikle kanser teşhisi, tümör segmentasyonu, lezyon tespiti ve hastalık sınıflandırma problemlerinde yüksek başarı oranları elde edilmektedir. [14]

Evrişimsel sinir ağları (CNN), tıbbi görüntü analizinde uzun süre en yaygın kullanılan derin öğrenme mimarilerinden biri olmuştur. CNN tabanlı modeller görüntüler üzerindeki lokal örüntüleri öğrenebilme yetenekleri sayesinde hücresel yapıların analizinde etkili sonuçlar vermektedir. Ancak klasik CNN mimarileri çoğu zaman uzun mesafeli bağımlılıkları ve global bağlamsal ilişkileri yeterince iyi modelleyememektedir.

Transformer tabanlı mimarilerin bilgisayarlı görü alanına uyarlanmasıyla birlikte Vision Transformer (ViT) ve Swin Transformer gibi modeller tıbbi görüntü analizinde önemli başarılar göstermiştir. Bu modeller dikkat (attention) mekanizması sayesinde görüntü üzerindeki farklı bölgeler arasındaki ilişkileri daha etkili şekilde öğrenebilmektedir. Özellikle histopatoloji görüntülerinde hem lokal hücresel detayların hem de global doku yapılarının birlikte değerlendirilmesi büyük önem taşımaktadır.

Derin öğrenme modellerinin başarısı büyük ölçüde veri miktarına bağlıdır. Ancak tıbbi görüntü veri setleri çoğu zaman sınırlı sayıda örnek içermektedir. Bu nedenle veri artırma (data augmentation) teknikleri yaygın olarak kullanılmaktadır. Döndürme, yansıtma, renk değişimi, bulanıklaştırma ve kırpma gibi işlemler sayesinde modelin farklı veri örüntülerini öğrenmesi sağlanmakta ve aşırı öğrenme (overfitting) problemi azaltılmaktadır. [14]

Tıbbi görüntü analizinde hibrit modellerin kullanımı da son yıllarda dikkat çekmektedir. Hibrit mimarilerde farklı derin öğrenme modellerinden elde edilen özellikler birleştirilerek daha güçlü temsiller oluşturulmaktadır. Böylece her modelin güçlü yönlerinden yararlanılması mümkün olmaktadır. Özellikle transformer tabanlı modeller ile CNN tabanlı yapıların birlikte kullanılması, hem global hem de lokal özelliklerin öğrenilmesine katkı sağlamaktadır.

Bu çalışmada Vision Transformer, Swin Transformer ve ConvNeXt mimarileri paralel şekilde kullanılmıştır. Elde edilen özellikler birleştirilerek hibrit bir özellik temsili oluşturulmuş ve son sınıflandırma işlemi için Support Vector Machine (SVM) algoritması kullanılmıştır. Böylece meme kanseri histopatoloji görüntülerinin daha yüksek doğrulukla sınıflandırılması hedeflenmiştir. [15]

2.3 Vision Transformer (ViT) Mimarisi

Vision Transformer (ViT), transformer tabanlı mimarilerin bilgisayarlı görü alanına uyarlanmasıyla geliştirilen derin öğrenme modellerinden biridir. İlk olarak doğal dil işleme alanında kullanılan transformer yapılarının görüntü işleme problemlerinde başarılı sonuçlar vermesiyle birlikte Vision Transformer mimarisi geliştirilmiştir. ViT modeli, görüntüleri küçük parçalara ayırarak her bir parçayı birer token olarak işlemekte ve dikkat mekanizması sayesinde görüntü üzerindeki global ilişkileri öğrenmektedir.

Geleneksel CNN tabanlı modeller görüntü üzerindeki lokal özellikleri öğrenmede başarılı olsa da uzak bölgeler arasındaki ilişkileri modelleme konusunda sınırlı kalabilmektedir. Vision Transformer mimarisi ise self-attention mekanizması kullanarak görüntünün farklı bölgeleri arasındaki uzun mesafeli bağımlılıkları daha etkili biçimde öğrenebilmektedir. Bu özellik özellikle histopatoloji görüntülerinde önemli avantaj sağlamaktadır.

Vision Transformer modelinde giriş görüntüsü belirli boyutlardaki patch'lere ayrılmaktadır. Her patch düzleştirilerek doğrusal gömme (linear embedding) işleminden

geçirilmektedir. Daha sonra bu gömülü temsile konumsal bilgiler eklenmekte ve transformer encoder bloklarına aktarılmaktadır. Böylece model hem patch içeriklerini hem de görüntü içerisindeki konumsal ilişkileri öğrenebilmektedir.

Transformer encoder yapısı çok başlıklı dikkat mekanizması (multi-head self-attention) ve tam bağlantılı katmanlardan oluşmaktadır. Self-attention mekanizması sayesinde model, görüntü üzerindeki önemli bölgeleri belirleyebilmekte ve farklı patch'ler arasındaki ilişkileri ağırlıklı şekilde değerlendirebilmektedir. Bu durum modelin global bağlamsal bilgiyi daha güçlü şekilde öğrenmesine katkı sağlamaktadır.

Vision Transformer mimarisi büyük veri setlerinde oldukça başarılı sonuçlar vermektedir. Ancak veri miktarının sınırlı olduğu durumlarda modelin aşırı öğrenme problemi yaşayabildiği bilinmektedir. Bu nedenle veri artırma yöntemleri ve transfer öğrenme yaklaşımları sıklıkla kullanılmaktadır. Özellikle tıbbi görüntü analizinde önceden eğitilmiş modellerin kullanılması performansı önemli ölçüde artırabilmektedir.

Histopatoloji görüntüleri yüksek çözünürlüklü ve karmaşık yapılar içerdiğinden Vision Transformer modelleri bu görüntülerde global doku örüntülerini öğrenmede etkili olmaktadır. Bununla birlikte yalnızca global özelliklere odaklanması bazı lokal detayların gözden kaçmasına neden olabilmektedir. Bu nedenle Vision Transformer modelleri çoğu zaman diğer derin öğrenme mimarileriyle birlikte hibrit yapılar kullanılmaktadır.

Bu çalışmada ViT-Base mimarisi hibrit modelin bir bileşeni olarak kullanılmıştır. Modelden elde edilen yüksek seviyeli özellikler Swin Transformer ve ConvNeXt mimarilerinden elde edilen özelliklerle birleştirilerek daha güçlü bir hibrit temsil oluşturulmuştur. Böylece hem global bağlamsal ilişkilerin hem de lokal hücrel detayların birlikte öğrenilmesi amaçlanmıştır.

2.4 Swin Transformer Mimarisi

Swin Transformer, transformer tabanlı mimarilerin hesaplama maliyetini azaltmak ve çok ölçekli özellik öğrenimini geliştirmek amacıyla geliştirilen hiyerarşik bir görüntü işleme modelidir. “Shifted Window Transformer” yaklaşımına dayanan bu mimari, görüntüyü sabit boyutlu pencerelere ayırarak dikkat mekanizmasını lokal bölgeler üzerinde uygulamaktadır. Böylece klasik Vision Transformer modellerine kıyasla daha düşük hesaplama maliyetiyle çalışabilmektedir. [16]

Vision Transformer modelleri tüm görüntü üzerinde global self-attention işlemi gerçekleştirdiğinden yüksek çözünürlüklü görüntülerde büyük hesaplama yükü oluşturmaktadır. Swin Transformer ise dikkat mekanizmasını yalnızca belirli pencere bölgeleri içerisinde uygulayarak bu problemi azaltmaktadır. Ayrıca pencere konumlarının kaydırılması sayesinde farklı bölgeler arasındaki ilişkiler de öğrenilebilmektedir.

Swin Transformer mimarisi çok aşamalı hiyerarşik bir yapıdan oluşmaktadır. Modelin ilk aşamalarında düşük seviyeli lokal özellikler öğrenilirken, ilerleyen katmanlarda daha yüksek seviyeli semantik temsiller elde edilmektedir. Bu yapı CNN mimarilerindeki çok ölçekli özellik öğrenimine benzer şekilde çalışmaktadır. [17]

Modelin temel bileşenlerinden biri shifted window attention mekanizmasıdır. İlk katmanda görüntü sabit pencerelere ayrılarak dikkat işlemi uygulanmaktadır. Sonraki katmanda ise pencere sınırları kaydırılarak farklı bölgeler arasındaki bilgi aktarımı sağlanmaktadır. Bu yaklaşım sayesinde model hem lokal hem de komşu bölgeler arasındaki ilişkileri etkili biçimde öğrenebilmektedir.

Swin Transformer mimarisi özellikle yüksek çözünürlüklü tıbbi görüntülerin analizinde önemli avantajlar sağlamaktadır. Histopatoloji görüntülerinde hücresel yapıların farklı ölçeklerde incelenmesi gerektiğinden çok seviyeli özellik öğrenimi büyük önem taşımaktadır. Swin Transformer modeli bu çok ölçekli yapıyı başarılı biçimde temsil edebilmektedir.

Ayrıca Swin Transformer modelleri sınırlı veri setlerinde Vision Transformer modellerine kıyasla daha kararlı sonuçlar verebilmektedir. Lokal pencere tabanlı dikkat mekanizması sayesinde modelin aşırı öğrenme eğilimi azaltılabilmektedir. Bu durum özellikle medikal görüntü veri setlerinde önemli bir avantaj oluşturmaktadır. [16]

Bu çalışmada Swin-Tiny mimarisi hibrit model yapısının ikinci bileşeni olarak kullanılmıştır. Modelden elde edilen hiyerarşik ve lokal dikkat tabanlı özellikler, Vision Transformer ve ConvNeXt mimarilerinden elde edilen özelliklerle birleştirilmiştir. Böylece farklı ölçeklerdeki doku örüntülerinin daha etkili biçimde temsil edilmesi amaçlanmıştır.

2.5 ConvNeXt Mimarisi

ConvNeXt, modern derin öğrenme yaklaşımlarını geleneksel evrimsel sinir ağlarıyla birleştiren yeni nesil bir CNN mimarisidir. Bu model, transformer tabanlı mimarilerin başarılı yönlerinden ilham alınarak geliştirilmiş olup klasik convolutional ağların performansını önemli ölçüde artırmayı amaçlamaktadır. ConvNeXt mimarisi özellikle görüntü sınıflandırma problemlerinde güçlü sonuçlar vermektedir.

Geleneksel CNN modelleri lokal özellikleri öğrenmede oldukça başarılıdır. Kenar, doku ve hücresel yapı gibi detayların çıkarılmasında convolution işlemleri etkili şekilde çalışmaktadır. Ancak transformer tabanlı modellerin ortaya çıkmasıyla birlikte CNN mimarilerinin bazı yapısal sınırlılıkları daha belirgin hale gelmiştir. ConvNeXt modeli, bu sınırlılıkları azaltmak amacıyla modern eğitim stratejileri ve mimari düzenlemeler kullanmaktadır.

ConvNeXt mimarisinde büyük kernel boyutları, derin katman yapıları ve geliştirilmiş normalization teknikleri kullanılmaktadır. Ayrıca residual bağlantılar ve modern aktivasyon fonksiyonları sayesinde modelin öğrenme kapasitesi artırılmaktadır. Bu yapı sayesinde CNN tabanlı modellerin lokal özellik öğrenme gücü korunurken daha güçlü temsiller elde edilmektedir. [17]

Model hiyerarşik bir yapı üzerinden çalışmaktadır. İlk katmanlarda düşük seviyeli görüntü özellikleri öğrenilirken, ilerleyen katmanlarda daha karmaşık ve soyut özellikler çıkarılmaktadır. Bu yaklaşım histopatoloji görüntülerindeki hücresel detayların etkili şekilde öğrenilmesine katkı sağlamaktadır.

ConvNeXt mimarisi özellikle medikal görüntü analizinde lokal yapısal detayların öğrenilmesi açısından önemli avantajlar sunmaktadır. Histopatoloji görüntülerinde hücre şekilleri, çekirdek yapıları ve doku dokuları gibi ince ayrıntılar sınıflandırma performansı açısından kritik rol oynamaktadır. CNN tabanlı yapıların bu lokal örüntüleri öğrenme başarısı, ConvNeXt mimarisinin medikal görüntü analizinde etkili sonuçlar vermesini sağlamaktadır.

Transformer tabanlı modeller global bağlamsal ilişkileri öğrenmede başarılı olurken, ConvNeXt gibi CNN tabanlı modeller lokal ayrıntıların öğrenilmesinde güçlü performans göstermektedir. Bu nedenle son yıllarda hibrit modellerde transformer ve CNN mimarilerinin birlikte kullanımı yaygınlaşmıştır.

Bu çalışmada ConvNeXt-Tiny mimarisi hibrit yapının üçüncü bileşeni olarak kullanılmıştır. ConvNeXt modelinden elde edilen lokal özellik temsilleri, Vision Transformer ve Swin Transformer modellerinden elde edilen özelliklerle birleştirilmiştir. Böylece hem global bağlamsal bilgiler hem de ince hücrel detaylar birlikte değerlendirilerek daha güçlü bir sınıflandırma sistemi oluşturulması amaçlanmıştır.

2.6 Özellik Füzyonu Yaklaşımları

Özellik füzyonu (feature fusion), farklı model veya veri kaynaklarından elde edilen özelliklerin birleştirilerek daha güçlü temsil öğrenimi oluşturulmasını sağlayan bir yöntemdir. Derin öğrenme tabanlı görüntü analiz çalışmalarında farklı mimarilerden elde edilen özelliklerin tek bir özellik uzayında birleştirilmesi, sınıflandırma performansını artırabilmektedir. Özellikle hibrit modellerde özellik füzyonu önemli bir rol oynamaktadır.

Tek bir derin öğrenme modeli çoğu zaman görüntü içerisindeki tüm yapısal bilgileri aynı anda etkili biçimde öğrenememektedir. CNN tabanlı modeller lokal örüntüleri başarılı şekilde öğrenirken, transformer tabanlı modeller global bağlamsal ilişkileri daha etkili biçimde analiz edebilmektedir. Bu nedenle farklı mimarilerin güçlü yönlerinin bir araya getirilmesi amacıyla özellik füzyonu yöntemleri kullanılmaktadır.

Özellik füzyonu işlemi genel olarak erken füzyon (early fusion), geç füzyon (late fusion) ve hibrit füzyon yaklaşımları şeklinde gerçekleştirilmektedir. Erken füzyonda ham veriler veya düşük seviyeli özellikler birleştirilirken, geç füzyonda modellerin çıktı sonuçları birleştirilmektedir. Hibrit füzyon yöntemlerinde ise farklı seviyelerdeki özellikler birlikte kullanılabilir.


Derin öğrenme tabanlı hibrit sistemlerde en yaygın kullanılan yöntemlerden biri özellik vektörlerinin birleştirilmesi (feature concatenation) yaklaşımıdır. Bu yöntemde farklı ağlardan elde edilen özellik vektörleri tek bir yüksek boyutlu özellik vektörü hâline getirilmektedir. Böylece model farklı ağların öğrenmiş olduğu tamamlayıcı bilgileri birlikte değerlendirebilmektedir.

Bu çalışmada Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özellikler birleştirilerek hibrit bir özellik temsili oluşturulmuştur. Transformer tabanlı modellerden elde edilen global dikkat tabanlı özellikler ile ConvNeXt mimarisinden elde edilen lokal hücrel detay özellikleri aynı özellik uzayında bütünleştirilmiştir. [17]

Özellik füzyonu sonrasında elde edilen yüksek boyutlu vektörler standardizasyon işleminden geçirilmiştir. Bu işlem sayesinde farklı ölçeklerdeki özelliklerin dengelenmesi sağlanmış ve sınıflandırma performansının artırılması amaçlanmıştır.

Ardından normalize edilen özellikler Support Vector Machine (SVM) sınıflandırıcısına aktarılmıştır.

Özellik füzyonu yaklaşımı sayesinde modelin hem global doku örüntülerini hem de lokal hücrel detayları birlikte öğrenebilmesi sağlanmıştır. Bu durum özellikle histopatoloji görüntülerinin karmaşık yapısının daha etkili biçimde temsil edilmesine katkı sağlamıştır.



Şekil 2.1. Hibrit özellik füzyon mekanizmasının genel yapısı

Şekilde Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özelliklerin birleştirilmesi, normalize edilmesi ve SVM tabanlı sınıflandırma süreci gösterilmektedir.

Özellik birleştirme işlemi aşağıdaki şekilde ifade edilmektedir:

$$F_{fusion} = [F_{ViT}; F_{Swin}; F_{ConvNeXt}]$$

Burada F_{ViT} , F_{Swin} ve $F_{ConvNeXt}$ ilgili derin öğrenme mimarilerinden elde edilen özellik vektörlerini ifade etmektedir. Birleştirme işlemi sonucunda oluşturulan F_{fusion} vektörü hibrit özellik temsilini oluşturmaktadır.

Önerilen hibrit mimaride her model farklı türde özellik temsilleri üretmektedir. Vision Transformer yapısı görüntünün global bağlamsal ilişkilerini öğrenirken, Swin Transformer çok ölçekli attention mekanizmaları sayesinde yerel ve bölgesel örüntüleri analiz etmektedir. ConvNeXt mimarisi ise CNN tabanlı yapısı sayesinde hücresel seviyedeki lokal doku detaylarını etkili biçimde çıkarabilmektedir.

Bu farklı mimarilerden elde edilen özellik vektörleri birleştirilerek daha güçlü ve zengin bir hibrit özellik temsili oluşturulmuştur. Özellik birleştirme işlemi sayesinde hem global hem de lokal doku örüntüleri aynı özellik uzayında temsil edilebilmiştir. Böylece meme kanseri histopatoloji görüntülerindeki karmaşık morfolojik yapıların daha etkili öğrenilmesi amaçlanmıştır. [18]

Birleştirme işleminden sonra özellik vektörleri normalize edilmiştir. Normalizasyon işlemi, farklı modellerden gelen özelliklerin aynı ölçek aralığında değerlendirilmesini sağlayarak sınıflandırma performansının daha kararlı hâle gelmesine katkı sağlamaktadır. Özellikle yüksek boyutlu özellik uzaylarında normalizasyon işlemi modelin daha dengeli öğrenme gerçekleştirmesi açısından önemli rol oynamaktadır.

Normalize edilen hibrit özellik vektörleri son aşamada SVM (Support Vector Machine) sınıflandırıcısına aktarılmıştır. SVM algoritması yüksek boyutlu özellik uzaylarında başarılı performans göstermesi nedeniyle tercih edilmiştir. Sınıflandırma sonucunda giriş histopatoloji görüntüsü benign (IDC-) veya malignant (IDC+) sınıflarından birine atanmıştır.

Önerilen hibrit özellik füzyon yaklaşımı sayesinde farklı derin öğrenme mimarilerinin güçlü yönleri bir araya getirilmiş ve tek bir modele kıyasla daha güçlü özellik temsilleri elde edilmesi amaçlanmıştır. Bu yapı aynı zamanda modelin sınıflandırma performansını artırırken karar mekanizmasının daha kararlı hâle gelmesine katkı sağlamıştır.

2.7 Support Vector Machine (SVM)

Support Vector Machine (SVM), sınıflandırma problemlerinde yaygın olarak kullanılan gözetimli makine öğrenmesi algoritmalarından biridir. SVM algoritmasının temel amacı farklı sınıflara ait örnekleri en uygun karar sınırı (hyperplane) ile birbirinden ayırmaktır. Özellikle yüksek boyutlu özellik uzaylarında etkili sonuçlar vermesi nedeniyle görüntü işleme ve biyomedikal veri analizi çalışmalarında sıklıkla tercih edilmektedir.

SVM algoritması, sınıflar arasındaki marjini (margin) maksimum seviyeye çıkarmayı amaçlamaktadır. Maksimum marjin yaklaşımı sayesinde modelin genelleme performansı artırılmakta ve aşırı öğrenme (overfitting) problemi azaltılabilmektedir. Karar sınırına en yakın bulunan örnekler destek vektörleri (support vectors) olarak adlandırılmakta ve modelin oluşturulmasında kritik rol oynamaktadır.

Lineer olarak ayrılabilen veri kümelerinde doğrusal hiper düzlem yeterli olmaktadır. Ancak gerçek dünya problemlerinde veriler çoğu zaman doğrusal olarak ayrılabilir yapıda değildir. Bu nedenle SVM algoritmasında kernel fonksiyonları kullanılmaktadır. Kernel yaklaşımı sayesinde veriler daha yüksek boyutlu özellik uzayına dönüştürülerek doğrusal olmayan sınıflandırma işlemleri gerçekleştirilebilmektedir. [18]

SVM algoritmasında yaygın olarak kullanılan kernel türleri doğrusal kernel (linear kernel), polinomsal kernel (polynomial kernel) ve radyal tabanlı fonksiyon kernelidir (Radial Basis Function – RBF). Özellikle karmaşık veri dağılımlarında RBF kernel daha başarılı sınıflandırma performansı sağlayabilmektedir. RBF kernel, örnekler arasındaki doğrusal olmayan ilişkilerin modellenmesine olanak sağlamaktadır.

Bu çalışmada hibrit derin öğrenme mimarisinden elde edilen yüksek boyutlu özellik vektörlerinin sınıflandırılması amacıyla RBF kernel tabanlı SVM algoritması kullanılmıştır. Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen özelliklerin birleştirilmesi sonucunda oluşan hibrit özellik uzayı üzerinde SVM sınıflandırıcısı uygulanmıştır.

SVM algoritması, yüksek boyutlu özellik uzaylarında güçlü genelleme performansı sunabilmesi nedeniyle tercih edilmiştir. Derin öğrenme modellerinden elde edilen hibrit özellik vektörleri, doğrudan tam bağlantılı katmanlarla sınıflandırılmak yerine RBF çekirdekli SVM sınıflandırıcısına aktarılmıştır. Bu yaklaşım özellikle sınırlı veri kümelerinde daha kararlı sonuçlar sağlayabilmektedir.


Bu çalışmada kullanılan SVM sınıflandırıcısında düzenleme parametresi (C) ve kernel parametreleri optimize edilerek en uygun sınıflandırma performansı elde edilmeye çalışılmıştır. SVM sınıflandırıcısı hibrit özellik temsili üzerinde karar sınırı oluşturarak IDC pozitif ve IDC negatif sınıflarının ayrımını gerçekleştirmiştir.

RBF çekirdekli SVM yaklaşımı sayesinde yüksek boyutlu hibrit özellik uzayında daha esnek karar sınırları oluşturulabilmektedir. Böylece histopatoloji görüntülerindeki karmaşık örüntülerin daha başarılı biçimde ayrıştırılması amaçlanmıştır.

SVM tabanlı sınıflandırma yaklaşımı sayesinde hibrit derin özelliklerin ayırt edici gücü artırılmış ve histopatoloji görüntülerinin daha başarılı biçimde

sınıflandırılması

sağlanmıştır.



Şekil 2.2. Hibrit derin özellikler üzerinde SVM tabanlı sınıflandırma süreci

Şekilde Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özelliklerin birleştirilmesi, standardizasyon işleminden geçirilmesi ve RBF çekirdekli SVM sınıflandırıcısı ile IDC pozitif/negatif sınıflandırmasının gerçekleştirilmesi gösterilmektedir.

$$f(x) = \text{sign} \left(\sum_{i=1}^n \alpha_i y_i K(x_i, x) + b \right)$$

Burada α_i destek vektör katsayılarını, y_i sınıf etiketlerini, $K(x_i, x)$ çekirdek (kernel) fonksiyonunu ve b bias terimini ifade etmektedir. Bu çalışmada doğrusal olmayan sınıf ayrımını gerçekleştirebilmek amacıyla RBF çekirdek fonksiyonu kullanılmıştır.

RBF çekirdekli SVM yaklaşımı sayesinde yüksek boyutlu hibrit özellik uzayında daha esnek karar sınırları oluşturulabilmektedir. Böylece histopatoloji görüntülerindeki karmaşık örüntülerin daha başarılı biçimde ayrıştırılması amaçlanmıştır. [18]

2.8 Grad-CAM ve Yorumlanabilir Yapay Zekâ

Grad-CAM (Gradient-weighted Class Activation Mapping), derin öğrenme modellerinin karar verme süreçlerini görselleştirmek amacıyla kullanılan yorumlanabilir yapay zekâ yöntemlerinden biridir. Bu yöntem, modelin sınıflandırma sırasında görüntünün hangi bölgelerine odaklandığını aktivasyon haritaları aracılığıyla göstermektedir. Özellikle tıbbi görüntü analizi çalışmalarında model kararlarının açıklanabilir olması büyük önem taşımaktadır.

Derin öğrenme modelleri yüksek doğruluk oranları elde edebilmesine rağmen çoğu zaman “kara kutu” yapılar olarak değerlendirilmektedir. Modelin hangi özellikleri dikkate alarak karar verdiğinin bilinmesi, özellikle sağlık alanındaki uygulamalarda güvenilirlik açısından önemli bir gereklilik oluşturmaktadır. Bu nedenle açıklanabilir yapay zekâ (Explainable Artificial Intelligence – XAI) yöntemleri son yıllarda yaygın biçimde kullanılmaya başlanmıştır. [19]

Grad-CAM yöntemi, hedef sınıfa ait gradyan bilgilerini kullanarak son katmanlardaki aktivasyon haritalarını ağırlıklandırmaktadır. Böylece modelin sınıflandırma kararına en fazla katkı sağlayan bölgeler belirlenebilmektedir. Elde edilen aktivasyon haritaları orijinal histopatoloji görüntüsü üzerine bindirilerek dikkat bölgeleri (attention regions) oluşturulmaktadır.

Bu çalışmada Grad-CAM yöntemi, hibrit derin öğrenme mimarisinin karar mekanizmasını görselleştirmek amacıyla kullanılmıştır. Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özellikler üzerinde oluşturulan aktivasyon haritaları sayesinde modelin özellikle tümöral bölgeler ve hücresel yapılar üzerinde yoğunlaştığı gözlemlenmiştir.

Grad-CAM yaklaşımı aşağıdaki şekilde ifade edilmektedir:

$$L_{Grad-CAM}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$$

Burada A^k son evrişim katmanındaki özellik haritalarını, α_k^c ilgili sınıfa ait önem ağırlıklarını ifade etmektedir. *ReLU* fonksiyonu ise yalnızca pozitif katkı sağlayan bölgelerin dikkate alınmasını sağlamaktadır.

Histopatoloji görüntülerinde Grad-CAM yöntemi sayesinde modelin kanserli bölgeleri hangi yapısal örüntülere göre değerlendirdiği analiz edilebilmektedir. Böylece modelin yalnızca rastgele örüntüler yerine biyolojik açıdan anlamlı bölgeleri kullanıp kullanmadığı gözlemlenebilmektedir.

Grad-CAM yöntemi, hibrit derin öğrenme mimarisinin karar mekanizmasını görselleştirmek amacıyla kullanılmıştır. Elde edilen aktivasyon haritaları sayesinde modelin özellikle hücresel yoğunluk, doku bozulmaları ve tümör bölgeleri üzerinde yoğunlaştığı gözlemlenmiştir. Böylece modelin kararlarının yorumlanabilirliği artırılmıştır. [19]



Şekil 3.1. Önerilen hibrit derin öğrenme tabanlı meme kanseri sınıflandırma sisteminin genel iş akışı.

3. MATERYAL VE YÖNTEM

Bu bölümde çalışmada kullanılan veri seti, veri ön işleme yöntemleri, hibrit derin öğrenme mimarisi, özellik füzyonu yaklaşımı ve sınıflandırma süreci ayrıntılı olarak açıklanmıştır. İlk olarak histopatoloji görüntülerinden oluşan veri seti tanıtılmış, ardından görüntülere uygulanan ön işleme ve veri artırma teknikleri ele alınmıştır. Devamında Vision Transformer (ViT), Swin Transformer ve ConvNeXt tabanlı hibrit mimarinin yapısı açıklanmış; özellik füzyonu ve SVM tabanlı sınıflandırma süreci detaylandırılmıştır. Ayrıca model eğitim stratejileri, performans değerlendirme metrikleri ve Grad-CAM tabanlı görselleştirme yöntemleri sunulmuştur.

3.1 Kullanılan Veri Seti

Bu çalışmada meme kanseri histopatoloji görüntülerinin sınıflandırılması amacıyla açık erişimli IDC (Invasive Ductal Carcinoma) histopatoloji veri seti kullanılmıştır. Veri seti, hematoksilin-eozin (H&E) boyama yöntemi ile hazırlanmış dijital patoloji görüntülerinden oluşmaktadır. Veri setinde invaziv duktal karsinom içeren (IDC_positive) ve içermeyen (IDC_negative) histopatoloji görüntüleri yer almaktadır.

IDC_positive sınıfı kanserli doku bölgelerini temsil ederken, IDC_negative sınıfı normal veya tümör içermeyen doku yapılarını ifade etmektedir. Bu yapı sayesinde derin öğrenme modellerinin malign ve benign histopatolojik örüntüler arasındaki farklılıkları öğrenmesi amaçlanmıştır. Veri seti; hücresel yoğunluk, çekirdek yapıları, doku bozulmaları ve tümör örüntüleri gibi önemli mikroskopik patolojik detaylar içermesi nedeniyle derin öğrenme tabanlı tıbbi görüntü analizi çalışmalarında yaygın olarak kullanılmaktadır.

Çalışma kapsamında veri seti eğitim, doğrulama ve test kümeleri olarak ayrılmıştır. Her sınıf için 12.000 eğitim, 2.500 doğrulama ve 2.500 test görüntüsü

kullanılmıştır. Böylece toplamda yaklaşık 34.000 histopatoloji görüntüsü ile deneysel çalışmalar gerçekleştirilmiştir. Veri ayrıştırma sürecinde sınıf dağılımının dengeli tutulmasına dikkat edilmiş ve modelin her iki sınıfı dengeli biçimde öğrenmesi hedeflenmiştir.

Model eğitim sürecinde görüntüler Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarilerine uygun giriş boyutlarına yeniden ölçeklendirilmiştir. Ayrıca veri artırma ve ön işleme aşamalarında rastgele kırpma (RandomResizedCrop), döndürme (RandomRotation), yatay-dikey çevirme (Horizontal/Vertical Flip), affine dönüşümler, renk çeşitlendirme (ColorJitter) ve Gaussian Blur gibi veri artırma teknikleri uygulanmıştır. Bunun yanında görüntüler normalize edilerek model eğitimine uygun hale getirilmiştir.


Histopatoloji görüntülerindeki boş veya arka plan ağırlıklı bölgelerin modele olumsuz etkisini azaltmak amacıyla patch extraction tabanlı ön işleme yaklaşımı uygulanmıştır. Bu süreçte görüntüler belirli boyutlardaki parçalara ayrılmış ve düşük bilgi içeren boş patch bölgeleri veri setinden çıkarılmıştır. Böylece modele daha anlamlı histopatolojik bölgelerin aktarılması amaçlanmıştır.

3.2 Veri Ön İşleme Süreci

Histopatoloji görüntüleri yüksek çözünürlüklü ve karmaşık yapılar içerdiğinden derin öğrenme modellerine doğrudan verilmeden önce çeşitli ön işleme adımlarından geçirilmiştir. Veri ön işleme süreci, modelin öğrenme performansını artırmak, gereksiz arka plan bölgelerini azaltmak ve görüntülerin standart bir yapıya dönüştürülmesini sağlamak amacıyla uygulanmıştır.

Bu çalışmada ön işleme aşamasında patch extraction, arka plan temizleme, yeniden boyutlandırma, standardizasyon ve veri dengeleme işlemleri gerçekleştirilmiştir. İlk olarak büyük boyutlu histopatoloji görüntüleri daha küçük parçalara ayrılmıştır. Daha sonra düşük bilgi içeren arka plan bölgeleri temizlenmiş ve görüntüler model giriş boyutlarına uygun hâle getirilmiştir.

Ön işleme süreci sayesinde modelin hücresel detaylara daha fazla odaklanabilmesi sağlanmış ve eğitim sürecindeki gereksiz hesaplama maliyeti azaltılmıştır. Ayrıca veri setinin dengeli hâle getirilmesiyle sınıf dengesizliği probleminin model performansı üzerindeki olumsuz etkileri azaltılmaya çalışılmıştır.



Şekil 3.2. Histopatoloji görüntülerine uygulanan veri ön işleme süreci
 Şekilde histopatoloji görüntülerine uygulanan patch extraction, arka plan patch'lerinin temizlenmesi ve hibrit derin öğrenme modeline veri hazırlama aşamaları gösterilmektedir

3.2.1 Patch Extraction Yapısı

Histopatoloji görüntüleri yüksek çözünürlüklü yapılar içerdiğinden derin öğrenme modellerinin görüntü üzerindeki lokal detayları daha etkili öğrenebilmesi amacıyla patch extraction yöntemi uygulanmıştır. Bu yöntemde büyük boyutlu görüntüler daha küçük parçalara ayrılarak modelin hücresel ve dokusal örüntülere odaklanması sağlanmıştır.

Bu çalışmada giriş görüntüleri 224×224 boyutuna yeniden ölçeklendirilmiş ve her görüntü 4×4 grid yapısına ayrılmıştır. Böylece her biri 56×56 boyutunda toplam 16 adet patch elde edilmiştir. Patch tabanlı yapı sayesinde görüntü içerisindeki farklı bölgeler ayrı ayrı analiz edilerek modelin lokal özellikleri daha ayrıntılı biçimde öğrenebilmesi amaçlanmıştır.

Patch extraction işlemi özellikle transformer tabanlı mimarilerde önemli bir rol oynamaktadır. Vision Transformer ve Swin Transformer mimarileri görüntüleri patch dizileri şeklinde işlediğinden, bu yaklaşım modelin dikkat mekanizması üzerinden farklı bölgelere odaklanabilmesini sağlamaktadır. Ayrıca ConvNeXt mimarisi ile birlikte kullanıldığında hem lokal hem de global özelliklerin birlikte öğrenilmesine katkı sağlamaktadır.

Patch extraction süreci sayesinde görüntü içerisindeki hücresel yoğunluk, çekirdek yapıları ve tümör bölgeleri daha belirgin biçimde temsil edilebilmiştir. Böylece hibrit modelin histopatoloji görüntülerindeki karmaşık yapıları daha etkili biçimde analiz edebilmesi hedeflenmiştir.

3.2.2 Arka Plan Temizleme

Histopatoloji görüntülerinde bazı bölgeler düşük bilgi içeren beyaz veya açık renkli arka plan alanlarından oluşabilmektedir. Bu bölgeler hücresel ve dokusal bilgi taşımadığından modelin öğrenme sürecine katkı sağlamamakta, aksine gereksiz hesaplama yükü oluşturmaktadır. Bu nedenle çalışmada arka plan temizleme işlemi uygulanmıştır.

Arka plan temizleme sürecinde patch extraction sonrasında elde edilen görüntü parçaları analiz edilmiş ve yüksek oranda boş alan içeren patch'ler veri setinden çıkarılmıştır. Böylece yalnızca anlamlı histopatolojik yapılar içeren bölgelerin model tarafından işlenmesi sağlanmıştır.

Bu yaklaşım sayesinde modelin dikkatinin biyolojik açıdan önemli hücresel yapılara yönlendirilmesi amaçlanmıştır. Özellikle tümör dokuları, çekirdek yoğunlukları ve doku bozulmaları gibi ayırt edici bölgelerin korunması hedeflenmiştir. Ayrıca gereksiz arka plan bölgelerinin kaldırılmasıyla eğitim sürecindeki hesaplama maliyeti azaltılmış ve model performansının artırılması amaçlanmıştır.

Arka plan temizleme işlemi hibrit mimarinin daha verimli çalışmasına katkı sağlamış ve özellik çıkarımı aşamasında daha anlamlı temsil öğrenimi elde edilmesine yardımcı olmuştur. Şekil 3.1'de arka plan patch'lerinin kaldırılması süreci görsel olarak gösterilmektedir.

3.2.3 Veri Dengeleme İşlemi

Histopatoloji veri setlerinde sınıflar arasındaki örnek sayılarının eşit olmaması sınıf dengesizliği problemine neden olabilmektedir. Bu durum derin öğrenme modellerinin çoğunluk sınıfına yönelmesine ve azınlık sınıfındaki örnekleri yeterince öğrenememesine yol açabilmektedir. Özellikle tıbbi görüntü analiz çalışmalarında sınıf dengesizliği model performansını doğrudan etkileyen önemli problemlerden biridir.

Bu çalışmada IDC pozitif ve IDC negatif sınıfları arasındaki dağılım dikkate alınarak veri dengeleme işlemleri uygulanmıştır. Amaç, modelin her iki sınıfa ait örüntüleri dengeli biçimde öğrenmesini sağlamak ve sınıflandırma performansını artırmaktır.

Veri dengeleme sürecinde eğitim veri setindeki sınıf dağılımları kontrol edilmiş ve sınıflar arasındaki dengesizliğin azaltılması hedeflenmiştir. Böylece modelin yalnızca baskın sınıfa odaklanmasının önüne geçilmeye çalışılmıştır. Ayrıca veri artırma teknikleri ile desteklenen dengeleme işlemleri sayesinde modelin genelleme yeteneğinin artırılması amaçlanmıştır.

Dengeli veri dağılımı sayesinde hibrit derin öğrenme modelinin hem IDC pozitif hem de IDC negatif görüntüler üzerinde daha kararlı sonuçlar üretmesi sağlanmıştır. Bu durum özellikle doğruluk, precision, recall ve F1-score gibi performans metriklerinin daha güvenilir biçimde değerlendirilmesine katkı sağlamıştır.

3.3 Veri Artırma Teknikleri


Derin öğrenme modellerinin yüksek performans gösterebilmesi için geniş ve çeşitli veri setlerine ihtiyaç duyulmaktadır. Ancak tıbbi görüntü veri setlerinde veri sayısının sınırlı olması ve sınıflar arasındaki dağılım farklılıkları modelin genelleme performansını olumsuz etkileyebilmektedir. Bu nedenle çalışmada veri artırma (data augmentation) teknikleri uygulanmıştır.

Veri artırma işlemleri sayesinde mevcut histopatoloji görüntülerinden farklı varyasyonlar üretilerek modelin farklı görüntü koşullarına karşı daha dayanıklı hâle gelmesi amaçlanmıştır. Böylece modelin yalnızca belirli örüntüleri ezberlemesi yerine daha genel özellikleri öğrenmesi hedeflenmiştir.

Bu çalışmada eğitim aşamasında görüntüler üzerinde yatay çevirme (horizontal flip), dikey çevirme (vertical flip), döndürme (rotation), affine dönüşüm (affine transform), renk değişimi (color jitter), bulanıklaştırma (Gaussian blur) ve rastgele kırpma (random resized crop) gibi veri artırma işlemleri uygulanmıştır. Uygulanan dönüşümler histopatoloji görüntülerinin temel yapısını koruyacak şekilde seçilmiş ve biyolojik anlamın bozulmamasına dikkat edilmiştir.

Veri artırma teknikleri özellikle sınırlı sayıdaki IDC pozitif örneklerin çeşitlendirilmesine katkı sağlamış ve modelin farklı tümör örüntülerini öğrenebilmesine yardımcı olmuştur. Ayrıca overfitting probleminin azaltılması ve modelin test verileri üzerindeki genelleme başarısının artırılması amaçlanmıştır.

Veri artırma işlemleri yalnızca eğitim veri seti üzerinde uygulanmış, doğrulama ve test veri setleri üzerinde herhangi bir dönüşüm gerçekleştirilmemiştir. Böylece model performansının gerçek veri dağılımı üzerinde objektif biçimde değerlendirilmesi sağlanmıştır.



Şekil 3.3. Çalışmada uygulanan veri artırma (data augmentation) süreci.

3.4 Hibrit Derin Öğrenme Mimarisi

Bu çalışmada meme kanseri histopatoloji görüntülerinin sınıflandırılması amacıyla transformer ve CNN tabanlı mimarilerin birlikte kullanıldığı hibrit bir derin öğrenme sistemi geliştirilmiştir. Önerilen yapı, Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarilerinden oluşan paralel bir özellik çıkarım yaklaşımına dayanmaktadır.


Bu çalışmada hibrit mimarinin tercih edilmesinin temel nedeni, farklı derin öğrenme modellerinin birbirini tamamlayan özelliklerinden yararlanabilmektir. Vision Transformer (ViT) modeli görüntü içerisindeki uzun menzilli ve global bağlamsal ilişkileri öğrenme konusunda güçlü performans sunarken, Swin Transformer modeli hem lokal hem de global özellikleri hiyerarşik yapı ile daha verimli biçimde temsil edebilmektedir. ConvNeXt mimarisi ise konvolüsyon tabanlı yapısı sayesinde hücresel detaylar ve lokal doku örüntülerinin öğrenilmesinde önemli avantajlar sağlamaktadır. Bu nedenle farklı mimarilerden elde edilen derin özelliklerin birleştirilmesiyle daha güçlü ve dengeli bir temsil öğrenimi elde edilmesi amaçlanmıştır. Transformer tabanlı modeller görüntü üzerindeki global bağlamsal ilişkileri öğrenmede başarılı olurken, CNN tabanlı modeller lokal hücresel detayların öğrenilmesinde etkili performans göstermektedir. Bu nedenle farklı mimarilerden elde edilen özelliklerin bir araya getirilmesiyle daha güçlü bir temsil öğrenimi hedeflenmiştir.

Çalışmada kullanılan hibrit mimaride histopatoloji görüntüleri aynı anda üç farklı derin öğrenme modeline aktarılmıştır. Vision Transformer modeli global dikkat tabanlı özellikleri öğrenirken, Swin Transformer modeli çok ölçekli ve pencere tabanlı dikkat mekanizması ile hiyerarşik özellikler çıkarmaktadır. ConvNeXt modeli ise lokal dokusal ve hücresel örüntülerin öğrenilmesinde görev almaktadır.

Her bir mimariden elde edilen derin özellik vektörleri daha sonra birleştirilerek hibrit bir özellik uzayı oluşturulmuştur. Böylece modelin hem lokal hem de global yapısal bilgileri birlikte değerlendirebilmesi amaçlanmıştır. Elde edilen hibrit özellikler standardizasyon işleminden geçirilmiş ve nihai sınıflandırma aşamasında SVM algoritmasına aktarılmıştır.

Önerilen hibrit yapı sayesinde histopatoloji görüntülerindeki karmaşık tümör örüntülerinin daha etkili biçimde temsil edilmesi hedeflenmiştir. Ayrıca paralel mimari yaklaşımı sayesinde farklı modellerin birbirini tamamlayıcı özelliklerinden yararlanılmıştır.

Bu çalışmada kullanılan hibrit derin öğrenme mimarisinin genel yapısı Şekil 3.4'de gösterilmektedir.



3.4.1 Vision Transformer Branch

Vision Transformer (ViT), görüntüleri sabit boyutlu parçalara ayırarak transformer tabanlı dikkat mekanizması ile analiz eden derin öğrenme mimarilerinden biridir. Geleneksel evrimsel sinir ağlarından farklı olarak ViT modeli, görüntüyü bir dizi patch şeklinde değerlendirerek global bağlamsal ilişkileri öğrenebilmektedir. Özellikle büyük ölçekli görüntü verilerinde uzun mesafeli bağımlılıkların öğrenilmesinde başarılı sonuçlar vermektedir.

Bu çalışmada hibrit mimarinin ilk bileşeni olarak ViT-Base modeli kullanılmıştır. Histopatoloji görüntüleri belirli boyutlardaki patch yapılarına ayrılmış ve her patch doğrusal gömme (linear embedding) işleminden geçirilmiştir. Daha sonra positional embedding kullanılarak patch konum bilgileri modele aktarılmıştır. Böylece transformer blokları görüntü üzerindeki mekânsal ilişkileri öğrenebilmektedir.

ViT mimarisinde self-attention mekanizması sayesinde görüntünün farklı bölgeleri arasındaki ilişkiler aynı anda değerlendirilebilmektedir. Bu durum özellikle histopatoloji görüntülerinde tümör bölgeleri ile çevresindeki doku yapılarının birlikte analiz edilmesine katkı sağlamaktadır. Modelin global dikkat mekanizması sayesinde yalnızca lokal örüntüler değil, geniş bağlamsal yapılar da öğrenilebilmektedir.

Transformer encoder blokları içerisinde Multi-Head Self-Attention (MHSA) ve feed-forward katmanları bulunmaktadır. Self-attention mekanizması giriş özellikleri arasındaki ilişkileri hesaplayarak önemli bölgelerin daha yüksek ağırlıklarla temsil edilmesini sağlamaktadır. Böylece modelin dikkat mekanizması histopatolojik örüntüler üzerinde yoğunlaşabilmektedir.

Bu çalışmada Vision Transformer branch yapısı hibrit model içerisinde global özellik çıkarımı amacıyla kullanılmıştır. Elde edilen özellik vektörleri daha sonra Swin Transformer ve ConvNeXt mimarilerinden elde edilen özelliklerle birleştirilerek hibrit özellik uzayı oluşturulmuştur.

3.4.2 ConvNeXt Branch

ConvNeXt, modern derin öğrenme yaklaşımlarını geleneksel evrimsel sinir ağları ile birleştiren gelişmiş CNN tabanlı mimarilerden biridir. Mimari yapı olarak transformer modellerinden ilham alınmasına rağmen temelinde evrim işlemi bulunmaktadır. ConvNeXt modeli özellikle lokal doku örüntülerinin öğrenilmesinde yüksek performans göstermektedir.

Bu çalışmada hibrit mimarinin üçüncü bileşeni olarak ConvNeXt-Tiny modeli kullanılmıştır. Histopatoloji görüntülerinden elde edilen patch yapıları evrim katmanları aracılığıyla analiz edilmiştir. Model, görüntü içerisindeki hücresel detayları, kenar yapılarını ve lokal doku örüntülerini öğrenerek ayırt edici özellik vektörleri üretmiştir.

ConvNeXt mimarisinde kullanılan derin evrim blokları sayesinde düşük seviyeli görsel özelliklerden yüksek seviyeli temsillere geçiş gerçekleştirilmektedir. Ayrıca residual bağlantılar ve normalize katmanları sayesinde eğitim süreci daha kararlı hâle getirilmektedir. Bu durum modelin karmaşık histopatolojik yapıları daha başarılı biçimde öğrenebilmesine katkı sağlamaktadır.

CNN tabanlı yapılar özellikle lokal komşuluk ilişkilerini analiz etmede başarılı olduğundan histopatoloji görüntülerindeki hücresel yoğunluk, çekirdek yapıları ve mikroskobik doku değişimleri ConvNeXt modeli tarafından etkili biçimde temsil edilebilmektedir. Böylece transformer tabanlı global özelliklere ek olarak güçlü lokal özellikler de hibrit sisteme kazandırılmıştır.

Bu çalışmada ConvNeXt branch yapısı hibrit mimari içerisinde lokal özellik çıkarımı amacıyla kullanılmıştır. Elde edilen derin özellikler Vision Transformer ve Swin Transformer mimarilerinden elde edilen özelliklerle birleştirilerek hibrit özellik füzyon sürecine aktarılmıştır.

3.5 Özellik Füzyonu Mekanizması

Bu çalışmada Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özellikler birleştirilerek hibrit bir özellik füzyonu mekanizması oluşturulmuştur. Özellik füzyonu yaklaşımının temel amacı, farklı mimarilerin öğrenmiş olduğu tamamlayıcı bilgileri tek bir özellik uzayında bütünleştirerek sınıflandırma performansını artırmaktır.

Transformer tabanlı mimariler görüntü üzerindeki global bağlamsal ilişkileri öğrenmede başarılı olurken, CNN tabanlı yapılar lokal hücresel detayların çıkarılmasında güçlü performans göstermektedir. Bu nedenle farklı modellerden elde edilen özelliklerin bir araya getirilmesi histopatoloji görüntülerinin daha kapsamlı biçimde temsil edilmesini sağlamaktadır.

Çalışmada her bir derin öğrenme modelinden elde edilen özellik vektörleri paralel biçimde çıkarılmış ve daha sonra concatenation işlemi kullanılarak birleştirilmiştir. Böylece yüksek boyutlu hibrit bir özellik vektörü oluşturulmuştur. Özellik birleştirme işlemi sırasında modellerin öğrenmiş olduğu global dikkat tabanlı bilgiler ile lokal dokusal örüntüler aynı özellik uzayında bütünleştirilmiştir.

Birleştirilen özellikler daha sonra standardizasyon işleminden geçirilmiştir. Standardizasyon sayesinde farklı ölçeklerdeki özelliklerin dengelenmesi sağlanmış ve sınıflandırma aşamasındaki öğrenme kararlılığı artırılmıştır. Bu işlem aynı zamanda yüksek boyutlu özellik uzayındaki dağılım farklılıklarının azaltılmasına katkı sağlamıştır. [23]

3.6 SVM Tabanlı Sınıflandırma

Support Vector Machine (SVM), hibrit derin özellik vektörlerinin sınıflandırılması amacıyla kullanılan gözetimli bir makine öğrenmesi algoritmasıdır. Bu çalışmada SVM algoritması, Vision Transformer, Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özelliklerin birleştirilmesi sonucunda oluşturulan hibrit özellik vektörleri üzerinde uygulanmıştır.


SVM algoritmasının temel amacı, farklı sınıfları birbirinden ayıran optimum karar sınırını (hyperplane) oluşturmaktır. Algoritma, sınıflar arasındaki marjini maksimum yapan hiper düzlemi belirleyerek sınıflandırma işlemini gerçekleştirmektedir. Maksimum marjin yaklaşımı sayesinde modelin genelleme performansının artırılması ve aşırı öğrenme (overfitting) probleminin azaltılması hedeflenmektedir.

Histopatoloji görüntülerinden elde edilen hibrit özellik vektörleri doğrusal olmayan dağılımlar içerdiğinden çalışmada RBF (Radial Basis Function) çekirdek fonksiyonu tercih edilmiştir. RBF çekirdeği sayesinde özellik uzayı daha yüksek boyutlu bir uzaya dönüştürülerek doğrusal olmayan sınıf ayrımlarının gerçekleştirilebilmesi sağlanmıştır. Böylece IDC pozitif ve IDC negatif örnekler arasındaki karmaşık örüntüler daha başarılı biçimde modellenenmektedir.

SVM sınıflandırıcısına aktarılmadan önce hibrit özellik vektörleri StandardScaler yöntemi kullanılarak standardizasyon işleminden geçirilmiştir. Bu işlem sayesinde farklı ölçeklerde bulunan özelliklerin dengelenmesi sağlanmış ve SVM algoritmasının daha kararlı çalışması amaçlanmıştır. Özellikle yüksek boyutlu özellik uzaylarında standardizasyon işlemi sınıflandırma performansı açısından önemli katkı sağlamaktadır.

Çalışmada kullanılan SVM modeli, Python Scikit-learn kütüphanesi kullanılarak geliştirilmiştir. Modelde RBF kernel, $C=2.0$ ve $\gamma=auto$ parametreleri kullanılmıştır. Ayrıca sınıf dengesizliğinin etkisini azaltabilmek amacıyla `class_weight="balanced"` parametresi tercih edilmiştir.

Eğitim işlemi sonrasında SVM modeli kullanılarak test verileri üzerinde tahminler gerçekleştirilmiş; doğruluk (accuracy), precision, recall, F1-score, ROC-AUC ve balanced accuracy metrikleri hesaplanmıştır. Ayrıca model performansının değerlendirilmesi amacıyla karmaşıklık matrisi (confusion matrix) ve ROC eğrisi analizleri oluşturulmuştur.



Şekil 3.5. Hibrit özellik vektörleri üzerinde gerçekleştirilen SVM tabanlı IDC sınıflandırma süreci gösterilmektedir.

3.7 Eğitim Stratejisi ve Hiperparametreler

Bu çalışmada hibrit derin öğrenme modeli aşamalı eğitim stratejisi kullanılarak eğitilmiştir. Eğitim sürecinde Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarilerinden elde edilen özellikler birleştirilmiş ve hibrit özellik uzayı oluşturulmuştur. Ardından elde edilen özellik vektörleri standardizasyon işleminden geçirilerek sınıflandırma aşamasına aktarılmıştır. [23]

Model eğitimi sırasında veri kümesi eğitim, doğrulama ve test olmak üzere üç farklı bölüme ayrılmıştır. Eğitim verileri modelin öğrenme sürecinde kullanılırken doğrulama verileri hiperparametre optimizasyonu amacıyla değerlendirilmiştir. Test verileri ise model performansının bağımsız olarak ölçülmesi amacıyla kullanılmıştır.

Derin öğrenme mimarilerinin eğitiminde transfer öğrenme yaklaşımı uygulanmıştır. Önceden büyük veri kümeleri üzerinde eğitilmiş modeller başlangıç ağırlıkları olarak kullanılmış ve histopatoloji veri kümesi üzerinde yeniden eğitilmiştir. Böylece modelin daha hızlı yakınsaması ve sınırlı veri kümesinde daha başarılı sonuçlar üretmesi amaçlanmıştır.

Model eğitiminde Adam optimizasyon algoritması tercih edilmiştir. Adam optimizasyon yöntemi adaptif öğrenme oranı mekanizması sayesinde derin öğrenme modellerinde kararlı ve hızlı öğrenme sağlayabilmektedir. Eğitim sürecinde öğrenme oranı, batch size ve epoch sayısı gibi hiperparametreler deneysel olarak optimize edilmiştir.

Aşırı öğrenme problemini azaltmak amacıyla dropout ve veri artırma tekniklerinden yararlanılmıştır. Ayrıca eğitim sürecinde erken durdurma (early stopping) yaklaşımı kullanılarak doğrulama kaybının artması durumunda eğitim işlemi sonlandırılmıştır. Bu sayede modelin genelleme performansının artırılması hedeflenmiştir. [20]

3.8 Performans Değerlendirme Metrikleri

Bu çalışmada önerilen hibrit derin öğrenme modelinin performansını değerlendirmek amacıyla çeşitli sınıflandırma metrikleri kullanılmıştır. Tıbbi görüntü analizi çalışmalarında yalnızca doğruluk (accuracy) metriği yeterli olmamakta, modelin pozitif ve negatif sınıfları ayırt etme başarısının da ayrıntılı biçimde incelenmesi gerekmektedir. Bu nedenle çalışmada accuracy, precision, recall, F1-score ve ROC-AUC metrikleri birlikte değerlendirilmiştir.

Doğruluk (accuracy), model tarafından doğru sınıflandırılan örneklerin toplam örnek sayısına oranını ifade etmektedir. Accuracy metriği genel performans hakkında bilgi vermesine rağmen sınıf dengesizliği bulunan veri kümelerinde tek başına yeterli olmayabilmektedir.

Precision metriği, modelin pozitif olarak tahmin ettiği örneklerin ne kadarının gerçekten pozitif olduğunu göstermektedir. Özellikle yanlış pozitif sonuçların önemli olduğu tıbbi uygulamalarda precision metriği büyük önem taşımaktadır. Recall metriği ise gerçek pozitif örneklerin ne kadarının doğru biçimde tespit edildiğini ifade etmektedir. Histopatoloji görüntülerinde kanserli bölgelerin kaçırılmaması açısından recall değeri kritik öneme sahiptir.

F1-score metriği precision ve recall değerlerinin harmonik ortalamasını ifade etmektedir. Bu metrik özellikle sınıf dağılımının dengesiz olduğu durumlarda model performansının daha dengeli biçimde değerlendirilmesini sağlamaktadır.

ROC-AUC metriği ise modelin farklı eşik değerleri altında sınıfları ayırt edebilme başarısını göstermektedir. AUC değerinin 1'e yaklaşması modelin sınıflandırma performansının yüksek olduğunu ifade etmektedir.

Bu çalışmada performans değerlendirme işlemleri bağımsız test veri kümesi üzerinde gerçekleştirilmiştir. Elde edilen sonuçlar sayesinde hibrit derin öğrenme modelinin IDC pozitif ve IDC negatif sınıflarını ayırt etme başarısı kapsamlı biçimde analiz edilmiştir.

3.9 Grad-CAM Görselleştirme Süreci

Derin öğrenme modellerinin karar mekanizmalarının yorumlanabilmesi, özellikle tıbbi görüntü analiz çalışmalarında büyük önem taşımaktadır. Bu nedenle çalışmada modelin hangi bölgeler üzerinde yoğunlaştığını görselleştirebilmek amacıyla Gradient-weighted Class Activation Mapping (Grad-CAM) yöntemi kullanılmıştır.

Grad-CAM yöntemi, modelin son katmanlarındaki aktivasyon haritaları ile gradyan bilgilerini birleştirerek sınıflandırma kararına en fazla katkı sağlayan bölgelerin belirlenmesini sağlamaktadır. Böylece modelin histopatoloji görüntüsünün hangi alanlarını dikkate alarak karar verdiği görsel olarak analiz edilebilmektedir.


Bu çalışmada Grad-CAM görselleştirmeleri hibrit derin öğrenme mimarisi üzerinde uygulanmıştır. Vision Transformer, Swin Transformer ve ConvNeXt tabanlı yapıların özellik çıkarım süreçlerinden elde edilen aktivasyon haritaları kullanılarak dikkat bölgeleri oluşturulmuştur. Özellikle ConvNeXt tabanlı uzamsal özellik haritaları Grad-CAM üretim sürecinde temel görsel açıklanabilirlik bileşeni olarak değerlendirilmiştir.

Grad-CAM sürecinde öncelikle giriş görüntüsü modele aktarılmış, ardından hedef sınıfa ait gradyanlar geri yayılım yöntemiyle hesaplanmıştır. Elde edilen gradyan ağırlıkları aktivasyon haritaları ile birleştirilerek sınıf aktivasyon haritaları oluşturulmuştur. Daha sonra dikkat haritaları normalize edilmiş, görsel kontrast iyileştirmeleri uygulanmış ve orijinal histopatoloji görüntüsü üzerine bindirilerek

görselleştirilmiştir. Böylece modelin odaklandığı bölgelerin daha yorumlanabilir ve görsel olarak daha belirgin hâle getirilmesi amaçlanmıştır.

Oluşturulan Grad-CAM görselleri sayesinde modelin özellikle hücresel yoğunluğun arttığı ve tümöral yapıların bulunduğu bölgeler üzerinde daha yüksek aktivasyonlar ürettiği gözlemlenmiştir. Bazı örneklerde dikkat bölgelerinin çevresel doku alanlarına da yayılım gösterebildiği görülmüştür. Bunun temel nedeninin histopatoloji görüntülerindeki karmaşık morfolojik yapılar ve hibrit mimarinin çoklu özellik çıkarım yaklaşımı olduğu değerlendirilmektedir.

Bu çalışmada elde edilen Grad-CAM çıktıları kesin segmentasyon haritaları olarak değil, modelin karar verme sürecindeki göreceli dikkat bölgelerini temsil eden yorumlanabilirlik haritaları olarak değerlendirilmiştir. Böylece hibrit modelin karar mekanizmasının daha açıklanabilir hâle getirilmesi amaçlanmıştır. [20]




Şekil 3.6’te hibrit model için oluşturulan örnek Grad-CAM görselleştirmeleri gösterilmektedir

4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

Bu bölümde önerilen hibrit derin öğrenme tabanlı meme kanseri sınıflandırma sisteminin deneysel sonuçları sunulmuştur. Modelin eğitim süreci, doğrulama


performansı, sınıflandırma sonuçları, confusion matrix analizleri ve ROC eğrileri detaylı olarak değerlendirilmiştir. Ayrıca Grad-CAM tabanlı yorumlanabilirlik analizleri gerçekleştirilmiş ve elde edilen bulgular literatürdeki çalışmalar ile karşılaştırılmıştır.

4.1 Eğitim ve Doğrulama Sonuçları



Şekil 4.1 Fusion model eğitim ve doğrulama doğruluk değişimi:

Önerilen hibrit modelin eğitim süreci boyunca eğitim ve doğrulama doğruluk değerleri takip edilmiştir. Şekil 4.1’de modelin epoch bazlı eğitim ve doğrulama doğruluk değişimleri gösterilmektedir. Eğitim doğruluğunun süreç boyunca düzenli biçimde arttığı ve yaklaşık %93 seviyesine ulaştığı gözlemlenmiştir. Doğrulama doğruluğu ise yaklaşık %91 seviyesinde stabil hale gelmiştir. Eğitim ve doğrulama eğrileri arasındaki farkın düşük seviyede kalması, modelin aşırı öğrenme göstermeden başarılı bir genelleme performansı sunduğunu göstermektedir. Ayrıca ilk epoch’larda hızlı bir öğrenme eğilimi gözlemlenirken ilerleyen epoch’larda doğruluk artışının daha kararlı hale geldiği belirlenmiştir [20]




Şekil 4.2 Fusion model öğrenme oranı (learning rate) değişim grafiği

Önerilen hibrit modele ait eğitim ve doğrulama kayıp değerleri Şekil 4.2’de gösterilmektedir. Eğitim süreci boyunca eğitim kaybının düzenli biçimde azaldığı gözlemlenmiştir. Bu durum modelin veri örüntülerini başarılı biçimde öğrendiğini göstermektedir. Doğrulama kaybının ise belirli bir seviyeden sonra stabil hale geldiği görülmektedir.

Eğitim ve doğrulama kayıp eğrileri arasındaki farkın düşük seviyede kalması modelin dengeli bir öğrenme süreci gerçekleştirdiğini göstermektedir. Bununla birlikte son epoch’larda eğitim kaybı azalmaya devam ederken doğrulama kaybında sınırlı düzeyde dalgalanmalar gözlemlenmiştir. Bu durum modelde hafif düzeyde aşırı öğrenme eğilimi oluşabileceğini göstermektedir. Ancak doğrulama performansının genel olarak stabil kalması modelin başarılı biçimde genelleme yapabildiğini ortaya koymaktadır [16].

Şekilde ayrıca en iyi doğrulama performansının yaklaşık 19–20. epoch civarında elde edildiği görülmektedir. Bu noktadan sonra doğrulama kaybındaki iyileşmenin sınırlı kaldığı belirlenmiştir.



Şekil 4.3 Fusion model öğrenme oranı (learning rate) değişim grafiği


Şekil 4.3'te eğitim sürecinde kullanılan öğrenme oranı planlaması (learning rate schedule) gösterilmektedir. Eğitim başlangıcında modelin veri örüntülerini hızlı biçimde öğrenebilmesi amacıyla daha yüksek öğrenme oranı kullanılmıştır. İlerleyen epoch'larda ise öğrenme oranı belirli aralıklarla kademeli olarak azaltılmıştır.

Öğrenme oranının kontrollü biçimde düşürülmesi sayesinde model parametrelerinin daha hassas güncellenmesi sağlanmış ve eğitim sürecinin kararlılığı artırılmıştır. Özellikle orta ve son epoch'larda öğrenme oranının azaltılması, modelin minimum kayıp değerlerine daha dengeli biçimde yakınsamasına katkı sağlamıştır. [16]

Şekilde görüldüğü üzere öğrenme oranı yaklaşık 8, 13, 16 ve 20. epoch civarında belirgin biçimde azaltılmıştır. Bu yaklaşım ani ağırlık güncellemelerini engelleyerek modelin daha stabil optimize edilmesini desteklemiştir. Son epoch'larda oldukça düşük öğrenme oranlarının kullanılması sayesinde doğrulama performansında daha kararlı sonuçlar elde edilmiştir.

4.2 Fusion Model Sonuçlar

Confusion matrix analizi, modelin yalnızca genel doğruluk performansını değil aynı zamanda sınıf bazlı tahmin başarısını da ayrıntılı biçimde değerlendirmeye olanak sağlamaktadır. Bu nedenle elde edilen True Positive (TP), True Negative (TN), False Positive (FP) ve False Negative (FN) değerleri kullanılarak accuracy, precision, recall ve F1-score gibi temel performans metrikleri hesaplanmıştır.



Şekil 4.4 Fusion modele ait confusion matrix sonuçları

Şekil 4.4'te önerilen Fusion modele ait confusion matrix sonuçları gösterilmektedir. Model toplam 4974 test örneği üzerinde değerlendirilmiştir. Sonuçlara göre 2286 örnek doğru şekilde IDC negatif (True Negative), 2263 örnek ise doğru şekilde IDC pozitif (True Positive) olarak sınıflandırılmıştır. Bunun yanında 205 örnek False Positive ve 220 örnek False Negative olarak tahmin edilmiştir. [12]

Elde edilen confusion matrix sonuçları modelin her iki sınıf üzerinde dengeli ve başarılı bir performans sergilediğini göstermektedir. Özellikle doğru pozitif tahmin sayısının yüksek olması modelin kanserli dokuları başarılı biçimde tespit edebildiğini göstermektedir. Ayrıca yanlış negatif (False Negative) değerinin görece düşük olması, kanserli dokuların gözden kaçırılma riskini azaltması açısından önemli bir avantaj sağlamaktadır. Modelin hem pozitif hem de negatif sınıflarda benzer performans göstermesi, hibrit özellik füzyonu yaklaşımının sınıflandırma başarısına olumlu katkı sağladığını ortaya koymaktadır.

Accuracy değeri modelin toplam doğru sınıflandırma oranını göstermektedir.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

Fusion model için:

TP = 2263

TN = 2286

FP = 205

FN = 220

değerleri kullanılmıştır.

$$Accuracy = \frac{2263+2286}{2263+2286+205+220} = 0.9146$$

Bu sonuç yaklaşık %91.46 doğruluk değerine karşılık gelmektedir.
Precision metriği, pozitif tahminlerin ne kadarının doğru olduğunu göstermektedir.

$$Precision = \frac{TP}{TP+FP}$$

$$Precision = \frac{2263}{2263+205} = 0.9169$$

Bu değer yaklaşık %91.69 olarak hesaplanmıştır.
Recall metriği modelin gerçek pozitif örnekleri yakalama başarısını ifade etmektedir.

$$Recall = \frac{TP}{TP+FN}$$

$$Recall = \frac{2263}{2263+220} = 0.9114$$

Bu sonuç yaklaşık %91.14 recall değerine karşılık gelmektedir.
F1-score değeri ise precision ve recall metriklerinin harmonik ortalaması olarak hesaplanmaktadır.


$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

$$F1 = 2 \times \frac{0.9169 \times 0.9114}{0.9169 + 0.9114} = 0.9142$$

Elde edilen sonuç yaklaşık %91.42 F1-score değerini göstermektedir. Hesaplanan metriklerin confusion matrix sonuçları ile tutarlı olduğu görülmektedir. [12]

Not: İlerleyen bölümde verilen SVM sınıflandırma sonuçları için de accuracy, precision, recall ve F1-score hesaplamalarında aynı performans metrik formülleri kullanılmıştır.

4.3 SVM Sınıflandırma Sonuçları



Şekil 4.5 SVM sınıflandırıcısına ait confusion matrix sonuçları

Şekil 4.5'te SVM tabanlı sınıflandırıcının test kümesi üzerindeki confusion matrix sonuçları gösterilmektedir. Confusion matrix analizi, modelin IDC_positive ve IDC_negative sınıflarını ne ölçüde doğru ayırabildiğini detaylı biçimde değerlendirmek amacıyla kullanılmıştır. [7]

SVM modeli toplam 4.974 örnek üzerinde değerlendirilmiştir. Model, 2.258 adet IDC_negative örneğini doğru şekilde negatif sınıf olarak sınıflandırırken (True Negative), 2.289 adet IDC_positive örneğini doğru şekilde pozitif sınıf olarak tahmin etmiştir (True Positive). Bunun yanında 233 adet False Positive ve 194 adet False Negative tahmini oluşmuştur.

False Positive (FP) sonuçları normal dokuların yanlış şekilde kanserli olarak sınıflandırıldığını göstermektedir. False Negative (FN) sonuçları ise kanserli dokuların yanlış biçimde normal olarak tahmin edildiğini ifade etmektedir. Özellikle tıbbi görüntü analizlerinde False Negative sonuçlar klinik açıdan daha kritik kabul edilmektedir. Çünkü kanserli dokuların gözden kaçırılması tanı ve tedavi sürecini olumsuz etkileyebilmektedir. [7]

Confusion matrix sonuçlarına göre SVM modelinin özellikle IDC_positive sınıfını başarılı şekilde ayırabildiği görülmektedir. Modelin düşük False Negative değeri, kanserli dokuların büyük bölümünü doğru şekilde tespit edebildiğini göstermektedir. Bu durum recall performansının yüksek olmasına katkı sağlamıştır.

SVM modeline ait performans metrikleri aşağıdaki formüller kullanılarak hesaplanmıştır:

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{F1-Score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Confusion matrix üzerinde elde edilen değerler kullanılarak hesaplanan performans sonuçları şu şekildedir:

$$\text{Accuracy} = 0.9142$$

$$\text{Precision} = 0.9076$$

$$\text{Recall} = 0.9219$$

$$\text{F1-Score} = 0.9147$$


$$\text{ROC-AUC} = 0.9526$$

Bu sonuçlar, SVM sınıflandırıcısının hibrit derin özellikler üzerinde yüksek genelleme performansı sunduğunu göstermektedir. Özellikle recall değerinin yüksek olması, modelin kanserli dokuları tespit etme başarısının güçlü olduğunu ortaya koymaktadır.

4.4 ROC Eğrisi ve AUC Analizi

ROC eğrisi analizi, özellikle tıbbi görüntü sınıflandırma problemlerinde modelin farklı karar eşikleri altındaki davranışını değerlendirmek açısından önemli bir performans ölçütü olarak kullanılmaktadır. Accuracy metriği genel sınıflandırma başarısını gösterirken, ROC-AUC analizi modelin sınıflar arasındaki ayrımı ne kadar başarılı gerçekleştirdiğini daha ayrıntılı biçimde değerlendirmeye olanak sağlamaktadır. Bu nedenle çalışmada önerilen hibrit fusion modelinin ayırt edici performansı ROC eğrisi ve AUC metriği kullanılarak ayrıca analiz edilmiştir. [7]

ROC eğrisi üzerinde eğrinin sol üst köşeye yakın ilerlemesi modelin yüksek duyarlılık (sensitivity) ve düşük yanlış pozitif oranı (False Positive Rate) ile çalıştığını göstermektedir. Özellikle histopatoloji tabanlı meme kanseri analizlerinde yanlış negatif sonuçların azaltılması kritik öneme sahip olduğundan ROC-AUC metriği model performansının değerlendirilmesinde önemli bir gösterge olarak kabul edilmektedir.




Şekil 4.6. Fusion model ROC eğrisi

Şekil 4.6’da önerilen Fusion modele ait ROC eğrisi gösterilmektedir. ROC (Receiver Operating Characteristic) eğrisi, modelin farklı eşik değerleri altında True Positive Rate (TPR) ve False Positive Rate (FPR) performansını değerlendirmek amacıyla kullanılmaktadır.

Grafikte ROC eğrisinin sol üst köşeye oldukça yakın ilerlediği görülmektedir. Bu durum modelin pozitif ve negatif sınıfları başarılı şekilde ayırabildiğini göstermektedir. Eğri altında kalan alanı ifade eden AUC (Area Under Curve) değeri 0.9682 olarak elde edilmiştir. [15]

ROC-AUC değerinin 1’e yakın olması modelin sınıflandırma başarısının yüksek olduğunu göstermektedir. Özellikle düşük False Positive Rate seviyelerinde yüksek True Positive Rate elde edilmesi, modelin kanserli dokuları başarılı biçimde tespit edebildiğini ortaya koymaktadır.

Fusion modelin yüksek ROC-AUC performansı, hibrit derin özellik füzyon yaklaşımının sınıflar arasındaki ayrımı güçlendirdiğini göstermektedir.



Şekil 4.7 SVM ROC eğrisi

Şekil 4.7’de SVM sınıflandırıcısına ait ROC eğrisi gösterilmektedir. ROC eğrisi, modelin farklı karar eşiklerinde sınıfları ayırt etme performansını değerlendirmek amacıyla kullanılmaktadır [15]

Grafik incelendiğinde ROC eğrisinin rastgele sınıflandırmayı temsil eden diagonal çizginin oldukça üzerinde konumlandığı görülmektedir. Bu durum SVM modelinin sınıflar arasında başarılı bir ayırım gerçekleştirdiğini göstermektedir. SVM modeline ait ROC-AUC değeri 0.9526 olarak hesaplanmıştır. Bu sonuç modelin yüksek ayırt edicilik performansına sahip olduğunu göstermektedir.

Özellikle düşük False Positive Rate seviyelerinde yüksek True Positive Rate elde edilmesi, modelin kanserli dokuları başarılı şekilde tespit edebildiğini ortaya koymaktadır.

Fusion model ile karşılaştırıldığında SVM modelinin ROC-AUC değerinin bir miktar daha düşük olduğu görülmektedir. Bununla birlikte elde edilen 0.9526 AUC değeri, hibrit derin özelliklerin SVM sınıflandırıcısı üzerinde etkili şekilde kullanılabildiğini göstermektedir.

Fusion model ve SVM sınıflandırıcısına ait ROC eğrileri birlikte değerlendirildiğinde her iki modelin de yüksek ayırt edicilik performansı sergilediği

görülmektedir. Ancak Fusion modelin ROC-AUC değerinin daha yüksek olması, hibrit özellik füzyon yaklaşımının sınıflar arasındaki ayrımı daha güçlü biçimde gerçekleştirebildiğini göstermektedir.

Fusion model için ROC-AUC değeri 0.9682 olarak elde edilirken, SVM modeli için bu değer 0.9526 olarak hesaplanmıştır. Elde edilen sonuçlar, Transformer ve CNN tabanlı özelliklerin birlikte kullanılmasının sınıflandırma performansına olumlu katkı sağladığını göstermektedir.

Özellikle Fusion modelin daha yüksek ROC-AUC performansı göstermesi, modelin benign ve malignant sınıfları arasındaki ayırt edici örüntüleri daha başarılı şekilde öğrenebildiğini ortaya koymaktadır. Bu durum hibrit mimarinin hem lokal hücrel detayları hem de global bağlamsal ilişkileri birlikte değerlendirebilmesinden kaynaklanmaktadır.

Sonuç olarak ROC eğrisi analizleri, önerilen Fusion modelin meme kanseri histopatoloji görüntülerinin sınıflandırılmasında daha güçlü, kararlı ve güvenilir bir performans sunduğunu göstermektedir.

Model	Accuracy	F1-Score	ROC-AUC
SVM	91.42	91.47	95.26
Fusion Model	91.46	91.42	96.82

4.5 Grad-CAM Analizleri

Bu bölümde önerilen hibrit modelin karar verme sürecinin yorumlanabilmesi amacıyla Grad-CAM (Gradient-weighted Class Activation Mapping) tabanlı görselleştirme analizleri gerçekleştirilmiştir. Grad-CAM yöntemi, modelin sınıflandırma sırasında görüntünün hangi bölgelerine daha fazla odaklandığını göstermekte ve derin öğrenme modellerinin yorumlanabilirliğini artırmaktadır.

Gerçekleştirilen Grad-CAM analizleri sonucunda modelin özellikle hücrel yoğunluğun arttığı ve tümöral yapıların bulunduğu bölgelerde daha yüksek aktivasyonlar ürettiği gözlemlenmiştir. Elde edilen dikkat haritalarında yüksek aktivasyon bölgelerinin çoğunlukla kanserli doku alanları üzerinde yoğunlaştığı belirlenmiştir. Bu durum modelin yalnızca rastgele örüntüler öğrenmediğini, aynı zamanda klinik açıdan anlamlı olabilecek morfolojik bölgeleri de dikkate alabildiğini göstermektedir.

Grad-CAM görselleştirmelerinde dikkat bölgelerinin daha net yorumlanabilmesi amacıyla aktivasyon haritaları normalize edilmiş, görsel kontrast iyileştirmeleri uygulanmış ve renk tabanlı dikkat haritaları ile desteklenmiştir. Böylece modelin odaklandığı bölgelerin görsel olarak daha belirgin hâle getirilmesi amaçlanmıştır.

Bazı örneklerde dikkat bölgelerinin çevresel doku alanlarına da kısmi yayılım gösterdiği gözlemlenmiştir. Bunun temel nedeninin histopatoloji görüntülerindeki karmaşık doku yapıları, sınıflar arasındaki morfolojik benzerlikler ve hibrit mimarinin çoklu özellik çıkarım yapısı olduğu değerlendirilmektedir. Bu nedenle Grad-CAM sonuçları kesin segmentasyon çıktıları olarak değil, modelin karar verme sürecindeki göreceli dikkat bölgelerini temsil eden yorumlanabilirlik haritaları olarak değerlendirilmelidir. [15]


Elde edilen görselleştirme sonuçları, önerilen hibrit Transformer-CNN mimarisinin meme kanseri histopatoloji görüntülerinde ayırt edici bölgeleri analiz edebildiğini ve karar mekanizmasının yorumlanabilirliğini artırdığını göstermektedir. Ayrıca Grad-CAM analizleri modelin klinik açıdan değerlendirilebilirliğini destekleyen önemli bir açıklanabilir yapay zekâ yaklaşımı sunmuştur.

4.6 Literatür ile Karşılaştırma

Bu çalışmada elde edilen sonuçlar literatürde yer alan güncel meme kanseri sınıflandırma çalışmaları ile karşılaştırılmıştır. Son yıllarda CNN ve Transformer tabanlı derin öğrenme mimarilerinin histopatoloji görüntülerinin analizinde yaygın olarak kullanıldığı görülmektedir. Özellikle Vision Transformer (ViT), Swin Transformer ve attention tabanlı hibrit yaklaşımlar hem global bağlamsal ilişkilerin hem de lokal hücresel detayların birlikte öğrenilmesine katkı sağlamaktadır. Literatürde Transformer-CNN tabanlı hibrit mimarilerin meme kanseri sınıflandırma performansını artırdığı rapore edilmiştir.

Bu çalışmanın geliştirilme sürecinde literatürde yaygın olarak kullanılan CNN tabanlı derin öğrenme mimarileri incelenmiş ve başlangıç aşamasında EfficientNet tabanlı bir model ile çeşitli ön deneyler gerçekleştirilmiştir. Bu ön deneylerde benign ve malignant sınıfları kullanılarak histopatolojik görüntüler üzerindeki temel sınıflandırma performansı değerlendirilmiştir. EfficientNet mimarisi kullanılarak eğitim-doğrulama doğruluğu, loss değişimleri, AUC performansı ve confusion matrix analizleri incelenmiştir.

Gerçekleştirilen ön çalışmalar, CNN tabanlı yaklaşımların meme kanseri sınıflandırmasındaki performansını gözlemlemek ve hibrit model tasarım sürecine altyapı oluşturmak amacıyla yapılmıştır. Eğitim süreci boyunca modelin doğruluk ve AUC değerlerinde düzenli artış gözlemlenmiş, loss değerlerinin ise epoch ilerledikçe azaldığı belirlenmiştir. Bununla birlikte histopatolojik görüntülerde yalnızca lokal özelliklerin değil aynı zamanda global yapısal örüntülerin de önemli olduğu değerlendirilmiştir. Bu nedenle çalışmanın ilerleyen aşamalarında CNN ve Transformer tabanlı özellik çıkarım mekanizmalarını birleştiren hibrit fusion mimarisi geliştirilmiştir.



Şekil 4.8’de EfficientNet tabanlı modelin eğitim ve doğrulama doğruluk (accuracy) değişimi gösterilmektedir.

Eğitim süreci boyunca hem eğitim hem de doğrulama doğruluk değerlerinin düzenli biçimde arttığı gözlemlenmiştir. Modelin eğitim doğruluğunun yaklaşık %86 seviyesine, doğrulama doğruluğunun ise yaklaşık %85 seviyesine ulaştığı görülmektedir. Eğitim ve doğrulama eğrilerinin birbirine yakın seyretmesi modelin dengeli bir öğrenme gerçekleştirdiğini ve aşırı öğrenme (overfitting) probleminin sınırlı seviyede kaldığını göstermektedir.

Özellikle epoch ilerledikçe doğruluk değerlerinin stabil hâle gelmesi, EfficientNet mimarisinin histopatoloji görüntülerindeki temel doku örüntülerini başarılı biçimde öğrenebildiğini göstermektedir. Elde edilen bu sonuçlar, modelin daha sonraki hibrit mimari geliştirme süreci için uygun bir başlangıç altyapısı sunduğunu ortaya koymaktadır. [15]




Şekil 4.9’de EfficientNet tabanlı modelin eğitim ve doğrulama loss değişimi gösterilmektedir.

Eğitim süreci boyunca loss değerlerinin genel olarak azalma eğiliminde olduğu görülmektedir. Özellikle eğitim loss eğrisinin düzenli biçimde düşmesi modelin veri üzerindeki örneklere giderek daha başarılı şekilde öğrenebildiğini göstermektedir. Doğrulama loss eğrisinin de eğitim loss eğrisi ile benzer davranış göstermesi modelin genelleme performansının dengeli olduğunu göstermektedir. [9]

Bazı epoch bölgelerinde kısa süreli dalgalanmalar gözlemlense de genel eğilim loss değerlerinin azaldığını göstermektedir. Eğitim ve doğrulama eğrileri arasındaki farkın düşük seviyede kalması aşırı öğrenme probleminin sınırlı olduğunu ve modelin kararlı bir eğitim süreci gerçekleştirdiğini göstermektedir.

Bu sonuçlar EfficientNet tabanlı yapının histopatoloji görüntülerindeki temel özellikleri öğrenebildiğini ve sınıflandırma problemi üzerinde başarılı bir optimizasyon süreci gerçekleştirdiğini ortaya koymaktadır.



Şekil 4.10'da EfficientNet modelinin eğitim ve doğrulama AUC değişimi gösterilmektedir.

Eğitim süreci boyunca AUC değerlerinin epoch ilerledikçe düzenli biçimde arttığını gözlemlenmiştir. Hem eğitim hem de doğrulama AUC değerlerinin yaklaşık 0.92 seviyesine ulaştığı görülmektedir. Bu durum modelin benign ve malignant sınıflarını başarılı biçimde ayırt edebildiğini göstermektedir.


Eğitim ve doğrulama AUC eğrilerinin birbirine oldukça yakın seyretmesi modelin dengeli bir öğrenme gerçekleştirdiğini ve genelleme performansının yüksek olduğunu göstermektedir. Özellikle ROC-AUC değerinin yüksek olması modelin farklı karar eşiklerinde de başarılı sınıflandırma performansı sergileyebildiğini ortaya koymaktadır. Elde edilen AUC sonuçları, EfficientNet mimarisinin histopatoloji görüntülerindeki ayırt edici örüntüleri öğrenebildiğini ve meme kanseri sınıflandırma probleminde etkili sonuçlar üretebildiğini göstermektedir.

Sınıf	Precision	Recall	F1-Score	Support
Benign	0.84	0.85	0.84	1995
Malignant	0.85	0.83	0.84	1983
Accuracy			0.84	3978
Macro Avg	0.84	0.84	0.84	3978
Weighted Avg	0.84	0.84	0.84	3978

Şekil 4.11’de EfficientNet tabanlı modele ait sınıflandırma performans sonuçları (classification report) gösterilmektedir.

Elde edilen sonuçlara göre modelin benign ve malignant sınıfları üzerinde dengeli bir performans sergilediği görülmektedir. Modelin genel doğruluk oranı %84 olarak hesaplanmıştır. Precision, recall ve F1-score değerlerinin birbirine oldukça yakın olması modelin kararlı bir sınıflandırma gerçekleştirdiğini göstermektedir. [9]

Benign sınıfı için precision değeri 0.84, recall değeri 0.85 ve F1-score değeri 0.84 olarak elde edilmiştir. Malignant sınıfında ise precision değeri 0.85, recall değeri 0.83 ve F1-score değeri 0.84 olarak hesaplanmıştır. Macro average ve weighted average sonuçlarının birbirine yakın olması modelin veri seti üzerinde dengeli öğrenme gerçekleştirdiğini göstermektedir.



Şekil 4.12 EfficientNet tabanlı ön modele ait confusion matrix sonuçları.

Şekil 4.12’de EfficientNet tabanlı ön deney modeline ait confusion matrix sonuçları gösterilmektedir. Elde edilen sonuçlara göre modelin benign ve malignant sınıfları üzerinde dengeli bir sınıflandırma performansı sergilediği görülmektedir. Model benign sınıfına ait 1700 örneği doğru sınıflandırırken 295 örneği yanlış tahmin etmiştir. Malignant sınıfında ise 1648 örnek doğru sınıflandırılmış, 335 örnek hatalı sınıflandırılmıştır.

Confusion matrix sonuçları incelendiğinde modelin her iki sınıf üzerinde de benzer performans gösterdiği ve genel olarak başarılı bir sınıflandırma gerçekleştirdiği görülmektedir. Eğitim sürecinde elde edilen doğruluk ve ROC-AUC sonuçları ile birlikte değerlendirildiğinde EfficientNet tabanlı yapının histopatoloji görüntülerindeki ayırt edici örüntüleri öğrenebildiği anlaşılmaktadır. Bu ön deney sonuçları daha sonraki aşamalarda geliştirilen hibrit Transformer-CNN mimarisinin oluşturulması için önemli bir altyapı sağlamıştır. [21]

Çalışma	Yöntem	Accuracy	ROC-AUC
EfficientNet Ön Deneyi	CNN	~85%	~0.92
SVM Hibrit Özellikler	ViT + Swin + ConvNeXt + SVM	91.42%	0.9526
Önerilen Fusion Model	Hybrid Transformer-CNN Fusion	91.46%	0.9682

Şekil 4.13 Literatürdeki çalışmalar ile performans karşılaştırması.

Şekil 4.13 incelendiğinde önerilen hibrit fusion modelin hem doğruluk hem de ROC-AUC performansı açısından diğer yaklaşımlara göre daha başarılı sonuçlar sunduğu görülmektedir. Özellikle Transformer ve CNN tabanlı özelliklerin birlikte kullanılması modelin hem global bağlamsal ilişkileri hem de lokal hücrel detayları daha etkili biçimde öğrenmesine katkı sağlamıştır. Ayrıca hibrit özelliklerin SVM sınıflandırıcısı ile değerlendirilmesi sınıflar arasındaki ayırım performansını güçlendirmiştir. [21]

4.7 Modelin Güçlü ve Zayıf Yönleri

Bu bölümde önerilen hibrit derin öğrenme tabanlı meme kanseri sınıflandırma modelinin güçlü ve zayıf yönleri değerlendirilmiştir. Modelin performans sonuçları, yorumlanabilirlik kapasitesi ve hesaplama maliyetleri dikkate alınarak genel bir analiz gerçekleştirilmiştir.

Önerilen modelin en önemli güçlü yönlerinden biri, farklı derin öğrenme mimarilerinin güçlü özelliklerini aynı yapı içerisinde birleştirebilmesidir. Vision Transformer ve Swin Transformer mimarileri görüntülerdeki global bağlamsal ilişkileri öğrenebilirken, ConvNeXt mimarisi lokal hücrel detayların analizinde başarılı sonuçlar sunmaktadır. Bu yapı sayesinde histopatoloji görüntülerindeki karmaşık örüntüler daha etkili biçimde temsil edilebilmiştir. [12]

Modelin bir diğer önemli avantajı hibrit özellik füzyonu yaklaşımıdır. Farklı mimarilerden elde edilen derin özelliklerin birleştirilmesi sayesinde sınıflandırma performansı artırılmıştır. Elde edilen yaklaşık %91 doğruluk ve 0.9682 ROC-AUC değeri modelin yüksek ayırt edicilik kapasitesine sahip olduğunu göstermektedir. Özellikle düşük False Negative oranı modelin kanserli dokuları başarılı biçimde tespit edebildiğini ortaya koymaktadır.

SVM tabanlı sınıflandırıcının kullanılması da modelin güçlü yönlerinden biridir. Yüksek boyutlu hibrit özellik uzaylarında SVM algoritmasının başarılı genelleme performansı sunduğu gözlemlenmiştir. Ayrıca Grad-CAM tabanlı görselleştirme analizleri modelin karar verme sürecinin yorumlanabilirliğini artırmış ve modelin klinik açıdan daha güvenilir değerlendirilmesine katkı sağlamıştır.

Bununla birlikte önerilen modelin bazı sınırlılıkları da bulunmaktadır. İlk olarak hibrit mimarinin birden fazla derin öğrenme modelini içermesi hesaplama maliyetini artırmaktadır. Eğitim sürecinde yüksek GPU belleği ve uzun eğitim süreleri gerekmektedir. Özellikle Transformer tabanlı mimarilerin parametre sayısının fazla olması eğitim sürecini daha karmaşık hale getirmektedir. [15]

Bir diğer sınırlılık Grad-CAM görselleştirme sonuçlarının bazı örneklerde yeterince belirgin olmamasıdır. Histopatoloji görüntülerinin karmaşık yapısı nedeniyle model zaman zaman çevresel doku bölgelerine de aktivasyon verebilmektedir. Ayrıca model performansının kullanılan veri setine bağlı olarak değişebileceği değerlendirilmektedir. Bu nedenle modelin farklı veri setleri üzerinde yeniden test edilmesi ve çapraz veri seti doğrulamalarının gerçekleştirilmesi önem taşımaktadır.

Genel olarak değerlendirildiğinde önerilen hibrit fusion modeli, meme kanseri histopatoloji görüntülerinin sınıflandırılmasında güçlü performans sunan başarılı bir derin öğrenme yaklaşımı olarak değerlendirilmiştir. Özellikle global ve lokal özelliklerin birlikte öğrenilmesi modelin sınıflandırma başarımını artırmış ve literatürdeki birçok geleneksel yaklaşıma göre daha başarılı sonuçlar elde edilmesini sağlamıştır.

5. SONUÇLAR VE ÖNERİLER

5.1 Sonuçlar

Bu çalışmada meme kanseri histopatoloji görüntülerinin sınıflandırılması amacıyla hibrit derin öğrenme tabanlı bir yaklaşım önerilmiştir. Çalışma kapsamında Vision Transformer (ViT), Swin Transformer ve ConvNeXt mimarilerinden elde edilen derin özellikler birleştirilerek hibrit bir feature fusion yapısı oluşturulmuştur. Elde edilen hibrit özellik vektörleri standardizasyon işleminden geçirilmiş ve nihai sınıflandırma aşamasında Support Vector Machine (SVM) sınıflandırıcısı kullanılmıştır. [18]

Çalışma sürecinde histopatoloji görüntülerine patch extraction, arka plan temizleme, veri dengeleme ve veri artırma işlemleri uygulanmıştır. Model eğitim sürecinde accuracy, loss ve learning rate değişimleri analiz edilerek öğrenme performansı değerlendirilmiştir. Ayrıca confusion matrix, ROC eğrisi, ROC-AUC analizi ve Grad-CAM tabanlı yorumlanabilirlik analizleri gerçekleştirilmiştir.

Elde edilen deneysel sonuçlara göre önerilen fusion modeli test veri seti üzerinde %91.46 accuracy, %91.69 precision, %91.14 recall ve %91.42 F1-score performansı elde etmiştir. Modelin ROC-AUC değeri ise 0.9682 olarak hesaplanmıştır. Bu sonuçlar önerilen hibrit mimarinin histopatoloji görüntülerindeki karmaşık tümör örüntülerini başarılı şekilde öğrenebildiğini göstermektedir. [4], [5]

SVM tabanlı hibrit özellik sınıflandırıcısında ise yaklaşık %91.42 accuracy ve 0.9526 ROC-AUC değeri elde edilmiştir. Özellikle ROC eğrisi analizleri değerlendirildiğinde fusion modelinin sınıflar arasındaki ayrımı yüksek doğrulukla gerçekleştirebildiği gözlemlenmiştir. Elde edilen yüksek ROC-AUC değerleri modelin güçlü ayırt edici özellik öğrenme kapasitesine sahip olduğunu göstermektedir.

Confusion matrix sonuçları incelendiğinde modelin IDC_positive ve IDC_negative sınıflarını dengeli biçimde sınıflandırabildiği görülmektedir. Özellikle recall değerinin yüksek olması, modelin kanserli dokuları yakalama başarısının güçlü

olduğunu göstermektedir. Histopatoloji tabanlı meme kanseri taramalarında false negative sonuçların klinik açıdan kritik öneme sahip olduğu düşünüldüğünde, elde edilen sonuçlar modelin güvenilirliği açısından önemli bir avantaj sunmaktadır. [12]

Grad-CAM tabanlı görselleştirme analizleri modelin özellikle tümör bölgeleri, hücresel yoğunluk alanları ve doku bozulmalarının bulunduğu bölgeler üzerine odaklandığını göstermiştir. Bu durum modelin yalnızca rastgele örüntüler öğrenmediğini, biyolojik açıdan anlamlı histopatolojik bölgeleri dikkate aldığını göstermektedir. Böylece önerilen sistemin yorumlanabilir yapay zekâ yaklaşımına katkı sağladığı değerlendirilmiştir. [4]

Genel olarak değerlendirildiğinde önerilen hibrit fusion modeli, Transformer tabanlı mimarilerin global bağlamsal öğrenme yeteneği ile CNN tabanlı mimarilerin lokal özellik çıkarım başarısını aynı sistem içerisinde birleştirerek meme kanseri histopatoloji görüntülerinin sınıflandırılmasında etkili ve başarılı sonuçlar sunmuştur.

Metrik	Değer
Accuracy	91.46%
Precision	91.69%
Recall	91.14%
F1-Score	91.42%
Balanced Accuracy	91.46%
ROC-AUC	0.9682

Çizelge 5.1 Önerilen hibrit modelin test performans sonuçları

5.2 Gelecek Çalışmalar İçin Öneriler

Bu çalışmada geliştirilen hibrit derin öğrenme tabanlı meme kanseri sınıflandırma modeli başarılı sonuçlar üretmiş olsa da, gelecekte gerçekleştirilecek çalışmalar ile model performansının, yorumlanabilirliğinin ve klinik uygulanabilirliğinin daha ileri seviyelere taşınması mümkündür.

İlk olarak modelin farklı histopatoloji veri setleri üzerinde test edilmesi ve çapraz veri seti doğrulamalarının gerçekleştirilmesi önerilmektedir. Böylece modelin farklı görüntü dağılımları üzerindeki genelleme performansı daha kapsamlı biçimde değerlendirilebilir. Özellikle farklı hastaneler ve farklı görüntüleme merkezlerinden elde edilen veri setleri kullanılarak modelin klinik ortamlardaki dayanıklılığı ve güvenilirliği analiz edilebilir. Bunun yanında daha büyük ve dengeli veri setlerinin kullanılması, modelin farklı tümör yapıları üzerindeki öğrenme kapasitesini artırabilir.

Gelecek çalışmalarda daha gelişmiş Transformer tabanlı mimarilerin kullanılması model performansını artırabilir. Özellikle daha büyük Vision Transformer modelleri, gelişmiş attention mekanizmaları ve çok ölçekli özellik çıkarım yaklaşımları histopatolojik örüntülerin daha etkili öğrenilmesine katkı sağlayabilir. Ayrıca self-supervised learning ve foundation model tabanlı yaklaşımlar ile daha güçlü temsil öğrenme yöntemleri geliştirilebilir. Bunun yanında federated learning yaklaşımları kullanılarak farklı merkezlerden elde edilen veriler üzerinde veri gizliliği korunarak ortak model eğitimi gerçekleştirilebilir.

Bu çalışmada kullanılan hibrit özellik füzyon yaklaşımı gelecekte multimodal yapay zekâ sistemleri ile genişletilebilir. Histopatoloji görüntülerinin klinik veriler, radyoloji görüntüleri, genetik bilgiler ve hasta geçmişi ile birlikte değerlendirilmesi daha güçlü tanı sistemlerinin geliştirilmesine olanak sağlayabilir. Bu tür multimodal sistemlerin klinik karar destek mekanizmalarında önemli katkılar sunabileceği düşünülmektedir.

Gelecekte açıklanabilir yapay zekâ yöntemlerinin geliştirilmesi de önemli araştırma alanlarından biri olabilir. Özellikle Grad-CAM, attention haritaları ve benzeri görsel yorumlanabilirlik yöntemlerinin daha ayrıntılı biçimde optimize edilmesi, modelin karar verme süreçlerinin daha şeffaf biçimde analiz edilmesine katkı sağlayabilir. Böylece klinik güvenilirlik artırılabilir ve uzman patoloğların modele duyduğu güven güçlendirilebilir. Ayrıca açıklanabilirlik yöntemlerinin kullanıcı dostu arayüzlerle desteklenmesi, model çıktılarının daha anlaşılır biçimde sunulmasını sağlayabilir.

Bunun yanında bu çalışmada geliştirilen interaktif kullanıcı arayüzü gelecekte daha kapsamlı klinik yazılım sistemlerine dönüştürülebilir. Özellikle gerçek zamanlı analiz desteği, Grad-CAM görselleştirmeleri, hasta bazlı raporlama sistemleri ve otomatik sonuç arşivleme gibi modüllerin eklenmesi klinik kullanım açısından önemli avantajlar sağlayabilir. Ayrıca web tabanlı veya bulut destekli platformların geliştirilmesi sayesinde sistemin farklı cihazlar üzerinden erişilebilir hâle getirilmesi mümkün olabilir.

Modelin gerçek zamanlı klinik uygulamalara uyarlanabilmesi amacıyla daha düşük hesaplama maliyetine sahip optimize mimarilerin geliştirilmesi de önemli araştırma alanlarından biridir. Özellikle model boyutunun küçültülmesi, inference süresinin azaltılması ve edge-device uyumlu sistemlerin geliştirilmesi klinik kullanım açısından avantaj sağlayabilir. Böylece yapay zekâ destekli histopatoloji analiz sistemlerinin hastane altyapılarına entegrasyonu kolaylaştırılabilir.

Sonuç olarak gelecekte gerçekleştirilecek çalışmalar ile hibrit derin öğrenme tabanlı sistemlerin daha güçlü, daha açıklanabilir, daha hızlı ve klinik açıdan daha uygulanabilir yapılar hâline getirilebileceği değerlendirilmektedir. Özellikle yapay zekâ destekli dijital patoloji sistemlerinin gelişmesiyle birlikte bu tür hibrit modellerin klinik karar destek süreçlerinde önemli rol oynayabileceği öngörülmektedir.

KAYNAKLAR

1. Bandi, P., Geessink, O., Manson, Q., Van Dijk, M., Balkenhol, M., Hermesen, M. ve Litjens, G., 2018, From detection of individual metastases to classification of lymph node status at the patient level: The CAMELYON17 challenge, *IEEE Transactions on Medical Imaging*, 38 (2), 550-560.
2. Campanella, G., Hanna, M. G., Geneslaw, L., Miraflor, A., Silva, V. W. K., Busam, K. J. ve Fuchs, T. J., 2019, Clinical-grade computational pathology using weakly supervised deep learning on whole slide images, *Nature Medicine*, 25 (8), 1301-1309.
3. Cortes, C. ve Vapnik, V., 1995, Support-vector networks, *Machine Learning*, 20 (3), 273-297.
4. Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T. ve Houlsby, N., 2021, An image is worth 16x16 words: Transformers for image recognition at scale, *International Conference on Learning Representations (ICLR)*.
5. Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M. ve Thrun, S., 2017, Dermatologist-level classification of skin cancer with deep neural networks, *Nature*, 542 (7639), 115-118.
6. He, K., Zhang, X., Ren, S. ve Sun, J., 2016, Deep residual learning for image recognition, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.
7. Huang, G., Liu, Z., Van Der Maaten, L. ve Weinberger, K. Q., 2017, Densely connected convolutional networks, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 4700-4708.
8. Janowczyk, A. ve Madabhushi, A., 2016, Deep learning for digital pathology image analysis: A comprehensive tutorial with selected use cases, *Journal of Pathology Informatics*, 7 (29), 1-29.
9. Komura, D. ve Ishikawa, S., 2018, Machine learning methods for histopathological image analysis, *Computational and Structural Biotechnology Journal*, 16, 34-42.
10. Kumar, N., Verma, R., Sharma, S., Bhargava, S., Vahadane, A. ve Sethi, A., 2017, A dataset and a technique for generalized nuclear segmentation for computational pathology, *IEEE Transactions on Medical Imaging*, 36 (7), 1550-1560.
11. LeCun, Y., Bengio, Y. ve Hinton, G., 2015, Deep learning, *Nature*, 521 (7553), 436-444.
12. Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M. ve Sánchez, C. I., 2017, A survey on deep learning in medical image analysis, *Medical Image Analysis*, 42, 60-88.

- 13.** Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z. ve Guo, B., 2021, Swin Transformer: Hierarchical vision transformer using shifted windows, Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 10012-10022.
- 14.** Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T. ve Xie, S., 2022, A ConvNet for the 2020s, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 11976-11986.
- 15.** Ronneberger, O., Fischer, P. ve Brox, T., 2015, U-Net: Convolutional networks for biomedical image segmentation, International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI), 234-241.
- 16.** Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. ve Batra, D., 2017, Grad-CAM: Visual explanations from deep networks via gradient-based localization, Proceedings of the IEEE International Conference on Computer Vision (ICCV), 618-626.
- 17.** Simonyan, K. ve Zisserman, A., 2015, Very deep convolutional networks for large-scale image recognition, International Conference on Learning Representations (ICLR).
- 18.** Solmaz, Ö. A. ve Tasci, B., 2025, ViSwNeXtNet Deep Patch-Wise Ensemble of Vision Transformers and ConvNeXt for Robust Binary Histopathology Classification, *Diagnostics*, 15 (12), 1507.
- 19.** Spanhol, F. A., Oliveira, L. S., Petitjean, C. ve Heutte, L., 2016, A dataset for breast cancer histopathological image classification, *IEEE Transactions on Biomedical Engineering*, 63 (7), 1455-1462.
- 20.** Tan, M. ve Le, Q., 2019, EfficientNet: Rethinking model scaling for convolutional neural networks, Proceedings of the 36th International Conference on Machine Learning (ICML), 6105-6114.
- 21.** Wang, X., Chen, H., Gan, C., Lin, H., Dou, Q., Huang, Q. ve Heng, P. A., 2021, Weakly supervised deep learning for whole slide lung cancer image analysis, *IEEE Transactions on Cybernetics*, 51 (7), 3950-3962.
- 22.** Yamashita, R., Nishio, M., Do, R. K. G. ve Togashi, K., 2018, Convolutional neural networks: An overview and application in radiology, *Insights into Imaging*, 9 (4), 611-629.
- 23.** Zhou, B., Khosla, A., Lapedriza, A., Oliva, A. ve Torralba, A., 2016, Learning deep features for discriminative localization, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2921-2929.


EKLER

EK-A. Geliştirilen Yapay Zekâ Destekli Kullanıcı Arayüzü


Bu ekte, çalışma kapsamında geliştirilen yapay zekâ destekli interaktif kullanıcı arayüzüne ait ekran görüntüleri ve sistem modülleri sunulmaktadır. Geliştirilen arayüz; histopatoloji görüntülerinin yüklenmesi, hibrit derin öğrenme tabanlı sınıflandırma işlemlerinin gerçekleştirilmesi, model eğitim süreçlerinin görselleştirilmesi ve performans analizlerinin kullanıcıya anlaşılır biçimde sunulabilmesi amacıyla tasarlanmıştır.

Sistem; Vision Transformer (ViT), Swin Transformer ve ConvNeXt tabanlı çoklu özellik çıkarım yapısını hibrit özellik füzyonu yaklaşımı ile birleştiren derin öğrenme mimarisi üzerine geliştirilmiştir. Ayrıca sınıflandırma aşamasında RBF-SVM tabanlı karar mekanizması kullanılarak daha güçlü ve dengeli sınıflandırma performansı elde edilmesi hedeflenmiştir. Arayüz içerisinde yer alan tüm modüller, model pipeline yapısını kullanıcıya görsel olarak aktarabilecek şekilde dinamik ve etkileşimli biçimde hazırlanmıştır.


Geliştirilen kullanıcı arayüzü yalnızca model çıktılarının gösterilmesini değil; aynı zamanda hibrit yapının çalışma mantığının açıklanmasını, eğitim sürecinin simülasyon destekli biçimde sunulmasını ve sınıflandırma performanslarının detaylı olarak analiz edilmesini de amaçlamaktadır. Bu doğrultuda sistem içerisinde canlı histopatoloji sınıflandırma ekranı, eğitim süreci simülasyonu, performans metrik panelleri, sınıf bazlı değerlendirme ekranları, confusion matrix analizleri ve hibrit SVM karar mekanizmasını görselleştiren modüller yer almaktadır.



Şekil EK-A.1 Canlı histopatoloji sınıflandırma arayüzü



Şekil EK-A.2 Eğitim süreci ve performans simülasyonu ekranı



Şekil EK-A.3 Hibrit SVM karar mekanizması görselleştirmesi

Arayüz tasarımında modern klinik yapay zekâ sistemlerinden esinlenilmiş olup koyu tema, gerçek zamanlı işlem göstergeleri, animasyon destekli pipeline akışı ve metrik panelleri kullanılarak profesyonel bir demonstrasyon ortamı oluşturulmuştur. Geliştirilen yapı; jüri sunumu, akademik demonstrasyon ve gelecekteki klinik karar destek sistemi entegrasyonları için temel oluşturabilecek şekilde tasarlanmıştır. Ayrıca sistemin modüler yapısı sayesinde ilerleyen çalışmalarda yeni derin öğrenme modelleri, açıklanabilir yapay zekâ yöntemleri ve multimodal veri yapıları arayüze entegre edilebilir yapıdadır.

Şekil EK-A.1’de geliştirilen canlı histopatoloji sınıflandırma arayüzü gösterilmektedir. Bu ekran üzerinden histopatoloji görüntüleri sisteme yüklenebilmekte ve hibrit derin öğrenme modeli kullanılarak otomatik sınıflandırma işlemleri gerçekleştirilebilmektedir.

Ayrıca model pipeline durumu, encoder yükleme aşamaları ve sınıflandırma süreci kullanıcıya gerçek zamanlı olarak görsel biçimde sunulmaktadır.

Şekil EK-A.2’de modelin eğitim süreci ve performans simülasyonu ekranı yer almaktadır. Bu bölümde eğitim doğruluğu, doğrulama doğruluğu, loss değerleri, epoch tabanlı ilerleme durumu ve checkpoint seçimi gibi süreçler görselleştirilmiştir. Eğitim sürecinin simülasyon destekli sunulması sayesinde model optimizasyon aşamaları kullanıcı tarafından daha anlaşılır biçimde takip edilebilmektedir.

Şekil EK-A.3’te hibrit derin özellik füzyonu ve SVM tabanlı karar mekanizmasının görselleştirilmiş yapısı sunulmaktadır. Görselde histopatoloji görüntülerinden elde edilen özelliklerin Vision Transformer, Swin Transformer ve ConvNeXt mimarileri üzerinden çıkarılması, özellik füzyonu işlemi ve RBF-SVM tabanlı sınıflandırma süreci şematik olarak gösterilmektedir. Böylece hibrit mimarinin uçtan uca çalışma akışı kullanıcıya görsel olarak aktarılmaktadır.

ÖZGEÇMİŞ

KİŞİSEL BİLGİLER

Adı Soyadı : Fatma Betül Pehlivan
Uyruğu : Türk
Doğum Yeri ve Tarihi : 30/01/2003, Meram / Konya / Türkiye
Telefon : 0551 188 38 00
Faks : -
E-mail : fbetulpehlivan.2003@gmail.com

EĞİTİM

Derece	Adı, İlçe, İl	Bitirme Yılı
Lise	: Mahmut Sami Ramazanoğlu İmam Hatip Lisesi	2022
Üniversite	: Selçuk Üniversitesi, Teknoloji Fakültesi, Bilgisayar Mühendisliği Bölümü, Konya	2027
Yüksek Lisans	: -	-
Doktora	: -	-

İŞ DENEYİMLERİ

Yıl	Kurum	Görevi
-	-	-

UZMANLIK ALANI

Yapay zekâ, derin öğrenme, tıbbi görüntü işleme, bilgisayarlı görü, web tabanlı yazılım geliştirme, Python programlama, ASP.NET Core Web API, React.js, veri analizi ve kullanıcı arayüzü geliştirme alanlarında çalışmalar yürütmektedir. Özellikle histopatoloji görüntülerinin derin öğrenme tabanlı analizi, hibrit Transformer-CNN mimarileri üzerine yoğunlaşmaktadır.

YABANCI DİLLER

İngilizce

BELİRTMEK İSTEDİĞİNİZ DİĞER ÖZELLİKLER

Derin öğrenme tabanlı tıbbi görüntü analizi ve histopatoloji görüntü sınıflandırması alanlarında akademik çalışmalar yürütmektedir. Özellikle Transformer mimarileri, hibrit derin öğrenme sistemleri, yorumlanabilir yapay zekâ yöntemleri ve gerçek zamanlı yapay zekâ destekli kullanıcı arayüzleri geliştirmeye ilgi duymaktadır.

YAYINLAR

Bulunmamaktadır.

Kontrol-Edilecek-Hususlar	Evet	Hayır
Sayfa yapısı uygun mu?		
Şekil ve çizelge başlık ve içerikleri uygun mu?		
Denklem yazımları uygun mu?		
İç kapak, onay sayfası, Proje bildirimi, özet, abstract, önsöz ve/veya teşekkür yazıldı mı?		
Proje yazımı; Giriş, Kaynak Araştırması, Materyal ve Yöntem (veya Teorik Esaslar), Araştırma Bulguları ve Tartışma, Sonuçlar ve Öneriler sıralamasında mıdır?		
Kaynaklar soyadı sırasına göre verildi mi?		
Kaynaklarda verilen her bir yayına proje içerisinde atıfta bulunuldu mu?		
Kaynaklar açıklanan yazım kuralına uygun olarak yazıldı mı?		
Proje içerisinde kullanılan şekil ve çizelgelerde kullanılan ifadeler Türkçe'ye çevrilmiş mi? (Latince ve Özel kelimeler hariçtir)		
Projenin içindekiler kısmı, proje içerisinde verilen başlıklara uygun hazırlanmış mı?		

Yukarıdaki verilen cevapların doğruluğunu kabul ediyorum.

Unvanı-Adı-SOYADI

İmza

Öğrenci→ :

Danışman→

*Bitirme projesi/araştırma projeleri: Teknoloji Fakültesi proje yazım kurallarına uygun olarak hazırlanmalıdır. Projeler teslim edilmeden önce yukarıdaki kontrol listesi öğrenci ve danışman tarafından imzalanmalıdır. Bu sayfa tez teslim esnasında en üst sayfa olarak verilmelidir.

* Proje ilk savunmaya sunulduğunda spiral cilt veya clip dosya formunda teslim edilmelidir.